



Trí tuệ Nhân tạo trong Sinh Tin học Artificial Intelligence in Bioinformatics

GS.TS. Đỗ Phúc
Trường Đại học Công nghệ Thông tin, ĐHQG TP.HCM

GS.TS. Đỗ Phúc, 2024

1

AI in Bioinformatics



GS.TS. Đỗ Phúc, 2024

2

Thông tin diễn giả

- GS. TS. Đỗ Phúc hiện đang làm việc tại Trường Đại học Công nghệ Thông tin, ĐHQG TP. HCM. Các lĩnh vực nghiên cứu của GS. bao gồm sinh tin học, xử lý văn bản, trí tuệ nhân tạo, học máy, học sâu, xử lý ngôn ngữ tự nhiên, đồ thị, trí tuệ, trả lời câu hỏi, kiểm tra sự đồng nhất, và xử lý dữ liệu lớn.
- Giáo sư đã tham gia nhiều dự án nghiên cứu trong nhiều lĩnh vực bao gồm sinh tin học, xử lý văn bản, xử lý ngôn ngữ tự nhiên, hệ thống hiểu văn bản và tập luận trên đồ thị tri thức.
- GS đã xuất bản hơn 60 bài báo khoa học trên các tạp chí uy tín quốc tế và trong nước. GS. là tác giả của 8 cuốn sách tham khảo, giáo trình trong lĩnh vực sinh tin học, khoa học máy tính, khai thác dữ liệu, đồ thị tri thức, dữ liệu lớn và ứng dụng.
- Email: phucdo@ut.edu.vn



GS.TS. Đỗ Phúc, 2024

3

Nội dung

- Giới thiệu về Sinh Tin học (bioinformatics hay computational biology)
 - Đồng lục
 - Cơ bản về tế bào
 - Sinh học số (digital biology)
 - Sinh Tin học
 - Mục tiêu của ngành Sinh Tin học
 - Cơ sở dữ liệu NCBI, PDB,...
 - Phát triển nghiên cứu ngành sinh tin học
 - Các kỹ thuật Tin học trong sinh tin học
 - Các phần mềm Sinh Tin học
 - Các chủ đề nghiên cứu của sinh tin học
 - Các ứng dụng của TTNT (học máy, học sâu) trong sinh tin học
- Trí tuệ nhân tạo (AI)
 - Các khóa học mới, các bài toán sinh tin học có độ phức tạp tính toán
 - Dùng ChatGPT với Sinh Tin học
 - Kết luận
 - Tài liệu tham khảo

GS.TS. Đỗ Phúc, 2024

4

Đồng lục



Những phát minh vĩ đại thường nằm giữa các biên giới của các ngành khoa học

GS.TS. Đỗ Phúc, 2024

5

GS.TS. Đỗ Phúc, 2024

6

Giải Nobel Y học vinh danh người tạo ra công nghệ vắc xin COVID-19

TPO - Chủ nhân giải Nobel lĩnh vực Y/Sinh học năm nay vừa được công bố, thuộc về hai nhà khoa học Katalin Karikó và Drew Weissman vì nghiên cứu về công nghệ mRNA, tạo nên công cụ quan trọng để hạn chế sự lây lan của đại dịch COVID-19.



Hai nhà khoa học Katalin Karikó (phải) và Drew Weissman trở thành chủ nhân của giải Nobel Y học 2023.

Prof. Dr. Do Phuc

7

Sinh học số: Cuộc cách mạng giúp con người trẻ khỏe (tuổi trẻ, 24-03-2024)

Nhiều ông lớn công nghệ như Netflix, Google và Microsoft đang đầu tư hàng tỉ USD vào công nghệ sinh học số (digital biology), xem đây là cuộc cách mạng mới của trí tuệ nhân tạo (AI), nơi hóa học giúp tạo ra những loại thuốc trị bệnh mới.



Các ông lớn công nghệ như Netflix, Google và Microsoft đã hàng tỉ USD vào phát triển công nghệ sinh học - Ảnh: Pexels

<https://tuoitre.vn/sinh-hoc-so-cuoc-cach-mang-giup-con-nguoi-tre-khoe-20240323224059013.htm>

GS.TS. Đỗ Phúc, 2024

8

Sinh học số: Cuộc cách mạng giúp con người trẻ khỏe (tuổi trẻ, 24-03-2024)

Nhờ AI cung cấp bộ công cụ mới để giải quyết những vấn đề phức tạp của hệ thống sinh học, "sinh học số" được đánh giá sẽ là cuộc cách mạng công nghệ đáng kinh ngạc tiếp theo.

Đây cũng là lĩnh vực kinh doanh được dự báo sẽ là ngành công nghiệp nhiều tỉ đô trong thời gian tới.



Những thành tựu đổi mới sáng tạo lớn nhất trong thế kỷ 21 sẽ nằm ở sự giao thoa giữa sinh học và công nghệ. Một kỷ nguyên mới đang bắt đầu.

Steve Jobs

AI và công nghệ sinh học

Ông Stephen Larson - CEO của MetaCell, công ty phát triển phần mềm khoa học thần kinh hàng đầu của Mỹ - mô tả sinh học số là lĩnh vực nghiên cứu "sử dụng phần mềm mô phỏng mạnh mẽ để hiểu các chức năng cơ bản của sự sống... để giúp chúng ta có cơ hội hiểu về những suy yếu của cơ thể."

GS.TS. Đỗ Phúc, 2024

9

Sinh học

Cơ thể cấu tạo từ các tế bào

Cơ thể của chúng ta được cấu tạo từ hàng tỷ tế bào, là những đơn vị cơ bản của sự sống. Tế bào có các chức năng cơ bản và đóng vai trò quan trọng trong cấu trúc và chức năng của cơ thể. Dưới đây là một số điểm chính về cấu tạo của tế bào:

1. **Màng tế bào (Cell Membrane):** Màng tế bào là lớp màng mỏng bao bọc tế bào và kiểm soát sự chất lượng của các chất đi vào và ra khỏi tế bào. Nó giữ cho môi trường nội bộ của tế bào khác biệt so với môi trường ngoại vi.
2. **Hạt nhân (Nucleus):** Hạt nhân là bộ phận quan trọng của tế bào, chứa DNA (Acid Deoxyribonucleic) và có trách nhiệm điều khiển các hoạt động của tế bào. DNA chứa thông tin gen di truyền và hướng dẫn sản xuất protein cần thiết cho sự sống.
3. **Citoplasma (Cytoplasm):** Citoplasma là chất nhầy nằm giữa màng tế bào và hạt nhân. Nó chứa nhiều cấu trúc nhỏ như ribosome (hạt ribonucleic), mitochondria, và các cấu trúc khác thực hiện các chức năng cụ thể trong tế bào.
4. **Ribosome:** Là các cấu trúc nhỏ không màng, thực hiện quá trình tổng hợp protein từ mã gen được mã hóa trong DNA.

Cơ thể chúng ta được cấu tạo từ các tế bào

1. **Tế bào da:** Đây là loại tế bào chiếm phần lớn trong lớp biểu bì, bảo vệ cơ thể khỏi các tác nhân bên ngoài như vi khuẩn, virus và tia tử ngoại.
2. **Tế bào cơ:** Cơ thể chúng ta có nhiều loại tế bào cơ khác nhau, bao gồm tế bào cơ trơn (co bóp không ý thức) và tế bào cơ nhịp tim (co bóp tim).
3. **Tế bào thần kinh:** Bao gồm tế bào thần kinh trung ương (nằm trong não và tủy sống) và tế bào thần kinh ngoại biên (nằm trong dây thần kinh và cảm giác).
4. **Tế bào máu:** Bao gồm tế bào hồng cầu (chuyên chở oxy), tế bào bạch cầu (phản ứng với vi khuẩn và virus), và tiểu cầu (tham gia vào quá trình đông máu).

GS.TS. Đỗ Phúc, 2024

12


Cơ thể chúng ta được cấu tạo từ các tế bào

- 5. **Tế bào gan:** Có vai trò quan trọng trong quá trình chuyển hóa, lọc độc tố và sản xuất các protein cần thiết cho cơ thể.
- 6. **Tế bào tiêu hóa:** Bao gồm tế bào niêm mạc ruột, tạo ra enzym và hấp thụ dưỡng chất từ thức ăn.
- 7. **Tế bào tuyến nội tiết:** Bao gồm tế bào tuyến giáp, tuyến tạo thái dương, tuyến thượng thận, và nhiều tuyến khác, điều chỉnh các quá trình nội tiết trong cơ thể.
- 8. **Tế bào miễn dịch:** Bao gồm tế bào B (tạo ra kháng thể) và tế bào T (phá hủy các tế bào nhiễm virus hoặc vi khuẩn).
- Các loại tế bào này cùng hoạt động cùng nhau để duy trì sự sống và hoạt động bình thường của cơ thể con người.

GS.TS. Đỗ Phúc, 2024

13

Các cấp độ tổ chức của cơ thể sống




GS.TS. Đỗ Phúc, 2024

14

Gene expression (biểu hiện gen)

- Gene expression (biểu hiện gen) là quá trình trong đó thông tin di truyền từ một gene được chuyển đổi thành một phản ứng sinh học, thường là một protein hoặc một RNA. Quá trình này bao gồm hai giai đoạn chính là transcription (phiên mã) và translation (dịch mã). Trong quá trình phiên mã, một gen được sao chép thành một RNA (messenger RNA hoặc mRNA). Sau đó, trong quá trình dịch mã, mRNA này được dịch thành một chuỗi amino acid để tạo thành một protein cụ thể.
- Gene expression là quá trình cơ bản quyết định sự phát triển, chức năng và hiện diện của tất cả các tổ chức sống.



GS.TS. Đỗ Phúc, 2024

15

Tiến trình phiên mã và dịch mã của tổng hợp protein từ DNA




Figure 2.3: Transcription and translation processes of protein synthesis.


GS.TS. Đỗ Phúc, 2024

16

DNA và Protein là hai đối tượng nghiên cứu chính của ngành Sinh Tin học

- DNA (Axit Deoxyribonucleic) và protein là hai đối tượng nghiên cứu chính trong Computational Biology
- 1. **DNA (Axit Deoxyribonucleic)**
 - Chức năng: DNA chủ yếu chứa thông tin di truyền và làm nhiệm vụ chính trong việc lưu trữ và truyền đạt thông tin di truyền từ một thế hệ sang thế hệ khác.
- 2. **Protein:**
 - Chức năng: Protein thực hiện nhiều chức năng quan trọng trong cơ thể như làm nhiệm vụ của enzym, vận chuyển chất, hỗ trợ cấu trúc tế bào, và tham gia vào nhiều quá trình sinh học khác.

James Watson (trái) và Francis Crick (phải) bên cạnh mô hình mà họ đã xây dựng về cấu trúc của DNA, 1953




<https://suckhoedoisong.vn/ai-la-nguoi-dau-tien-tim-ra-chuoi-adn-vat-lieu-di-truyen-cua-tat-ca-sinh-the-169221007100600715.htm>

GS.TS. Đỗ Phúc, 2024

18

Mô hình DNA

- Theo mô hình này, DNA là phân tử có cấu trúc xoắn kép gồm 2 mạch polynucleotide - song song và ngược chiều nhau ($3'-5'$ và $5'-3'$) xoắn đều từ trái sang phải quanh một trục tương đương theo chu kỳ, mỗi chu kỳ xoắn gồm 10 cặp nucleotide.
- Hai mạch nucleotide liên kết với nhau theo nguyên tắc bổ sung (A liên kết T bằng 2 liên kết hydrogen, G liên kết với C bằng 3 liên kết hydrogen)
- Trên phân tử DNA, trình tự của nucleotide mang thông tin mã hóa cho một sản phẩm polypeptide hoặc RNA được gọi là gene. DNA có vai trò truyền đạt thông tin di truyền nhờ quá trình tái bản DNA trong phân bào



GS.TS. Đỗ Phúc, 2024

19

Protein


- Protein là đại phân tử sinh học chiếm tỷ lệ nhiều nhất trong cơ thể sinh vật
- Protein có cấu tạo theo nguyên tắc đa phân, mỗi đơn phân là một amino acid

GS.TS. Đỗ Phúc, 2024

20

Các bậc cấu trúc của Protein

- Cấu trúc bậc 1:** được hình thành do các AA liên kết với nhau bằng liên kết peptide
- Cấu trúc bậc 2:** Chuỗi polypeptide ở dạng xoắn lò xo alpha hay gấp phiến beta
- Cấu trúc bậc 3:** Chuỗi polypeptide bậc 2 tiếp tục co xoắn thành cấu trúc không gian 3d. Cấu trúc không gian này quyết định chức năng sinh học của phân tử
- Cấu trúc bậc 4:** Một số phân tử protein được hình thành do liên kết từ 2 hay nhiều chuỗi polypeptide bậc 3 tạo thành cấu trúc bậc 4



GS.TS. Đỗ Phúc, 2024

21

Vài chức năng quan trọng của protein

- 1. Xây dựng và sửa chữa cơ bắp: Protein là thành phần chính của cơ bắp, giúp xây dựng và sửa chữa cấu trúc cơ bắp sau khi chúng bị tổn thương hoặc mòn.
- 2. Hỗ trợ trong quá trình trao đổi chất: Các enzyme, một dạng protein, đóng vai trò quan trọng trong quá trình trao đổi chất, giúp tăng tốc các phản ứng hóa học cần thiết cho sự sống.
- 3. Tạo ra kháng thể: Các protein miễn dịch giúp tổ chức hệ thống miễn dịch của cơ thể, bảo vệ chúng ta khỏi các vi khuẩn, virus và tác nhân gây bệnh khác.
- 4. Cung cấp năng lượng: Protein cung cấp năng lượng cho cơ thể khi cần thiết, đặc biệt là khi nguồn năng lượng từ các nguồn khác như carbohydrate và lipid bị thiếu hụt.
- 5. Truyền dẫn tín hiệu: Một số loại protein đóng vai trò trong việc truyền dẫn tín hiệu trong cơ thể, giúp điều chỉnh các chức năng cơ bản như tín hiệu dây thần kinh và hormonal.
- 6. Giữ nước trong cơ thể: Một số protein trong cơ thể giữ nước, giúp duy trì sự cân bằng nước và các chất điện giải trong cơ thể.
-

GS.TS. Đỗ Phúc, 2024

22

Sinh tin học

GS.TS. Đỗ Phúc, 2024

23

Sinh tin học Bioinformatics, Computational Biology, Khoa học liên ngành



GS.TS. Đỗ Phúc, 2024

24


Tin học ?

- Xuất phát từ tiếng Pháp *informatique* là *tin học*
- Định nghĩa:
Tin học (informatics) khoa học xử lý thông tin
- Liên hệ đến các lĩnh vực khác
 - Y tin học (medical informatics)
 - Sinh tin học (bio-informatics)

GS.TS. Đỗ Phúc, 2024

25

Sinh tin học xuất phát từ đâu?



Dữ liệu từ đề án bộ gene người đã thúc đẩy phát triển ngành **Sinh tin học**

GS.TS. Đỗ Phúc, 2024

26

Sinh tin học?

Cor

- (Phân từ) **Bio - informatics**
- Ý tưởng định nghĩa?
Sinh tin học hiểu **sinh học theo phân tử** (nghĩa hóa lý), dùng **các kỹ thuật tin học** để hiểu và tổ chức thông tin sinh học trên quy mô lớn
- Khoa học liên ngành với Toán, Tin, Sinh, Hóa, Lý.

GS.TS. Đỗ Phúc, 2024

27

Thông tin?

Sinh học phân tử như là khoa học về thông tin

- Nền tảng chính của sinh học phân tử

DNA
-> RNA
-> Protein
-> Phenotype
-> DNA

- Phân tử

Sequence, Structure, function
Mechanism
Specificity, regulation

Genetic material
Information transfer (mRNA)
Protein synthesis (RNA/mRNA)
Gene catalytic activity

- Chiến lược trung tâm của sinh tin học

Genomic Sequence Information
-> mRNA (level)
-> Protein Sequence
-> Protein Structure
-> Protein Function
-> Phenotype

- Số lượng thông tin lớn

- Chuẩn hóa

- Thống kê

Most cellular functions are performed or facilitated by proteins
Primary biocatalyst
Cofactor transport/storage
Mechanical motor/suppor
Immune protection
Control of growth/differentiation

GS.TS. Đỗ Phúc, 2024

28


Sự tăng trưởng của dữ liệu sinh học

- GenBank đã phát triển nhanh chóng trong những năm gần đây với tốc độ tăng gấp đôi khoảng mỗi 18 tháng. Phiên bản 250.0, được công bố vào tháng 6 năm 2022, chứa hơn 17 nghìn tỷ cơ sở nucleotide trong hơn 2,45 tỷ trình tự.
- CSDL PDB (Cơ sở dữ liệu Protein) có 214,111 mục PDB và bao gồm 14,482 cấu trúc protein tính đến năm 2023.
- Mục tiêu chính của Dự án Gen người (HGP), diễn ra từ năm 1990 đến năm 2003, là xác định cả hai chuỗi DNA và vị trí của khoảng 100,000 gen của con người.
- Nhiều dự án nghiên cứu gen, xác định cấu trúc protein được mã hóa trong bộ gen... đã tạo ra một lượng lớn thông tin sinh học, và thông tin này ngày càng trở nên đa dạng và phong phú.

GS.TS. Đỗ Phúc, 2024

29


Thông tin quy mô lớn: Sự tăng trưởng của GenBank



GS.TS. Đỗ Phúc, 2024

30

Thông tin Sinh học phân tử Cấu trúc đại phân tử sinh học



GS.TS. Đỗ Phúc, 2024


37

Thông tin sinh học phân tử Chi tiết về cấu trúc protein

Statistics on Number of XYZ triplets

- 200 residues/domain → 200 CA atoms, separated by 3.8 Å
- Avg. Residue is Leu: 4 backbone atoms + 4 sidechain atoms, 150 cubic Å or a bead of diameter 6.6 Å
- ~1500 xyz triplets (=8x200) per protein domain
- 10 K known domains but only ~300 folds

ATOM	1	C	ACE	0	9.451	30.148	40.503	1.00	49.88	1000	67
ATOM	2	O	ACE	0	10.432	30.820	40.722	1.00	50.35	1000	68
ATOM	3	CH3	ACE	0	8.876	29.707	39.224	1.00	50.04	1000	69
ATOM	4	N	SSB	1	8.753	29.755	41.085	1.00	49.13	1000	70
ATOM	5	CA	SSB	1	10.242	30.250	42.074	1.00	48.42	1000	71
ATOM	6	C	SSB	1	10.453	29.550	43.379	1.00	41.99	1000	72
ATOM	7	O	SSB	1	10.555	29.607	44.054	1.00	41.24	1000	73
ATOM	8	CB	SSB	1	8.052	30.189	42.074	1.00	53.00	1000	74
ATOM	9	CG	SSB	1	7.289	31.450	42.002	1.00	57.79	1000	75
ATOM	10	H	ARG	2	11.300	29.810	42.877	1.00	50.48	1000	76
ATOM	11	CA	ARG	2	12.548	28.310	43.532	1.00	50.20	1000	77
ATOM	12	C	ARG	2	13.552	29.501	43.500	1.00	25.94	1000	78



GS.TS. Đỗ Phúc, 2024

38

Hệ gene

Hệ gen (genome) là tổng số thông tin di truyền hoặc tất cả các gen mà một tổ hợp cụ thể của các sinh vật (như một tế bào, một cá thể hay một loài) chứa đựng. Nó bao gồm tất cả các gen và các phần không mã hóa nằm giữa chúng. **Gen là đơn vị cơ bản của di truyền, và hệ gen chứa toàn bộ thông tin cần thiết để xây dựng và duy trì một sinh vật.**

Human Genome: Trong ngữ cảnh của con người, hệ gen con người được đặt tên là "genome." Hệ gen con người chứa các gen điều khiển các đặc điểm di truyền như màu da, mắt, chiều cao, cũng như các gen quy định chức năng của các protein và nhiều khía cạnh khác của sinh học. Nghiên cứu về hệ gen là một lĩnh vực quan trọng trong di truyền học và sinh học phân tử để hiểu rõ về cấu trúc và chức năng của các gen.

GS.TS. Đỗ Phúc, 2024

39

Thông tin sinh học phân tử: Hệ Genomes

Dữ liệu tích hợp 1995,

- HI (vi khuẩn): 1.6 Mb và 1600 gen đã được hoàn thành 1997,
- năm men: 13 Mb và khoảng 6000 gen cho năm men 1998,
- giun sán: ~100Mb với 19 nghìn gen 1999:
- Hơn 30 gen bản đồ đã hoàn thành! 2003, người: 3 Gb và 100 nghìn gen...

GS.TS. Đỗ Phúc, 2024

40

Human genome project (HGP)

- Dự án Bộ gen người (Human Genome Project - HGP) là một dự án quốc tế quy mô lớn đã được bắt đầu vào những năm 1990 và hoàn thành chính thức vào năm 2003.
- Mục tiêu chính của dự án này là **đọc toàn bộ chuỗi gen của con người, tức là xác định thứ tự chính xác của các cặp nucleotide trong DNA của con người.**
- Nhờ vào sự tiến triển nhanh chóng trong công nghệ sinh học và giảm giá thành của việc xác định chuỗi gen, HGP đã tạo ra một bản đồ gen chi tiết, giúp hiểu rõ hơn về cấu trúc gen của con người.
- Dự án này đã cung cấp thông tin quan trọng để nghiên cứu về gen học, y học, và những ứng dụng lâm sàng, từ việc chẩn đoán bệnh đến phát triển phác đồ điều trị cá nhân hóa.
- Kết quả của HGP đã có tác động lớn đối với nhiều lĩnh vực khoa học và y học, mở ra những cơ hội mới cho nghiên cứu và phát triển trong lĩnh vực gen học và **y học phân tử.**

GS.TS. Đỗ Phúc, 2024

41

Human Genome Project

- Số Gene:** Con người được ước tính có khoảng 20,000 - 25,000 gene. Trước HGP, ước tính ban đầu là có khoảng 100,000 gene, nhưng sau khi hoàn thành, con số này giảm đáng kể.
- Số Nucleotide (bp - cặp nucleotide):** Chuỗi DNA của con người có khoảng 3 tỷ cặp nucleotide (bp).
- Số Khoảng Trắc Địa (SNP - Single Nucleotide Polymorphism):** Các biến đổi một nucleotide (SNP) trong gen con người là những thay đổi thường xuyên xảy ra. Dự án Gen Học đã tìm và định rõ khoảng 10 triệu SNP trên toàn bộ chuỗi gen.
- Kích thước Genomes:** Chuỗi gen của mỗi con người có một số độ dài cụ thể, nhưng thường nằm trong khoảng 2.85 tỷ đến 3.2 tỷ cặp nucleotide.
- Thời Gian và Chi Phí:** Dự án Gen Học kéo dài từ năm 1990 đến 2003 và có chi phí ước tính là khoảng 3 tỷ đô la Mỹ.

GS.TS. Đỗ Phúc, 2024

42


Vài nhân vật chính của HGP

- **James D. Watson**
 - là người đoán định cấu trúc của DNA cùng với Francis Crick vào năm 1953. Trong giai đoạn đầu của HGP, ông đã đóng vai trò quan trọng trong việc thúc đẩy dự án và đưa ra những ý kiến quan trọng
- **Francis Collins**
 - nhà sinh học phân tử, ông đã đóng vai trò quan trọng trong việc lãnh đạo dự án và giám đốc Viện Y học Quốc gia (National Institutes of Health - NIH).
- **Craig Venter**
 - Nhà gen học nổi tiếng, Craig Venter đã đóng góp quan trọng trong việc giải rỗng và nhanh chóng hóa quy trình xác định chuỗi gen.
- **Alec Jeffreys**
 - Alec Jeffreys là nhà di truyền học người Anh, được biết đến với việc phát hiện kỹ thuật vết mầu dấu gen (DNA fingerprinting).

GS.TS. Đỗ Phúc, 2024

43

Giới thiệu NCBI



NCBI

- Cơ sở dữ liệu NCBI (National Center for Biotechnology Information) là một tổ chức thuộc Viện Y học Quốc gia Hoa Kỳ (National Institutes of Health - NIH). NCBI chủ yếu chịu trách nhiệm về việc cung cấp và duy trì một loạt các cơ sở dữ liệu quan trọng trong lĩnh vực sinh học phân tử và y học. Một số cơ sở dữ liệu quan trọng của NCBI bao gồm:
- 1. **PubMed**: Cơ sở dữ liệu này chứa thông tin về các bài báo khoa học từ nhiều lĩnh vực y học và sinh học.
- 2. **GenBank**: GenBank là một cơ sở dữ liệu lớn chứa thông tin về các dãy nucleotide của DNA, RNA và protein được thu thập từ nhiều nguồn khác nhau.
- 3. **BLAST (Basic Local Alignment Search Tool)**: Cung cấp các công cụ tìm kiếm dãy nucleotide và protein trong các cơ sở dữ liệu để xác định sự giống nhau và quan hệ họ hàng.

GS.TS. Đỗ Phúc, 2024

45

NCBI

- 4. **Entrez Gene**: Dữ liệu gen và thông tin liên quan về chúng, bao gồm thông tin về vị trí gen, sản phẩm protein, và nhiều thông tin khác.
- 5. **PubMed Central (PMC)**: Là kho lưu trữ mở của bài báo y học, cung cấp nguồn tài liệu miễn phí cho cộng đồng nghiên cứu.
- 6. **Genome Database (GDB)**: Lưu trữ và cung cấp thông tin gen liên quan đến các loài.
- Các cơ sở dữ liệu này hỗ trợ cộng đồng nghiên cứu trong việc truy cập và chia sẻ thông tin quan trọng về gen, protein, và các khía cạnh khác của sinh học phân tử.

GS.TS. Đỗ Phúc, 2024

46

NCBI là gì?

NCBI: National Center for Biotechnological Information.

Điều hành nỗ lực thu thập thông tin Sinh Tin học


CSDL và công cụ Sinh Tin học

Hỗ trợ sinh viên truy cập

Cho phép Nhà NC phân tích dữ liệu mong muốn


Cho phép nhà nghiên cứu diễn giải dữ liệu

Chúng ta có gì từ NCBI?




Ứng dụng

1. Nghiên cứu và thực hiện công việc in silico rồi sau đó dùng thí nghiệm vật lý.
2. Khởi đầu phân tích và so sánh giữa các mô hình cây trồng và động vật khác nhau.
3. Dữ liệu genôm có thể truy cập như các cấp cơ sở, kích thước, protein, gen có trách nhiệm cho một bệnh cụ thể.
4. Giảm khoảng cách hiểu biết và làm cho việc xác định enzym đích dễ hơn.




Search for NCBI in Google page.




Enter into the website.


NCBI home page.



Nhập nucleotide vào hộp hoạt xuất hiện và tìm kiếm một loài hữu cơ. Ở đây, tôi đã chọn Lúa.



Nhập đây FASTA của nhóm Oryza sativa japonica.



Các chuỗi đã được sao chép và nhập vào BLAST.Công cụ tìm kiếm trình tự tương đồng trong CSDL.


Chuỗi nucleotide đã được dán và sau đó chạy BLAST..



Running status.

Kết quả cho thấy các Chuỗi tương tự.

Các chuỗi dịch được hiển thị khi nhập mã truy cập..

Cần chỉnh hiển thị điểm số, đồng nhất và khoảng trống cho mỗi loài tương tự tương ứng.





CSDL trình tự Protein

- CSDL trình tự Protein được phân loại như sơ cấp, hỗn hợp, thứ cấp.
- CSDL sơ cấp chứa trên 300,000 trình tự protein và chức năng của nó, đây là một kho lưu trữ dữ liệu thô.
- Một số kho lưu trữ dữ liệu phổ biến chung như SWISS-PROT, và PIR chứa các trình tự, chức năng protein, cấu trúc và những thay đổi sau khi dịch mã.

GS.TS. Đỗ Phúc, 2024

63


CSDL cấu trúc Protein

- Ngân hàng dữ liệu Protein, PDB cung cấp tất cả cấu trúc 3D của các đại phân tử như protein, RNA, DNA và những phức hợp khác, hiện CSDL có chừng 13,000 cấu trúc (tháng 8 năm 2000) được phân giải bằng phương pháp tán xạ tia x và NMRb.
- PDBsum cung cấp một trang Web riêng cho từng cấu trúc trong PDB chứa các chi tiết các phân tích cấu trúc, các biểu đồ và dữ liệu tương tác giữa các phân tử khác nhau..

GS.TS. Đỗ Phúc, 2024

64

Cấu trúc Protein



Phát triển nghiên cứu ngành sinh tin học

- Hai nhiệm vụ chính của ngành Sinh Tin học là **tổ chức và hiểu biết** dữ liệu sinh học – sự phát triển của công nghệ sinh tin học cho phép mở rộng những phân tích sinh học theo 2 chiều, sâu và rộng.
- Theo bề sâu sẽ bao gồm các nghiên cứu nhằm hiểu biết ngày càng nhiều các protein. Bắt đầu với một gen, xác định chuỗi protein, từ đó **dự đoán cấu trúc của protein**.
- Dựa vào các tính toán hình học có thể dự đoán hình dạng và bề mặt protein, mô phỏng phân tử phân tử.
- Nhận diện liên kết, và suy đoán chức năng protein.
- **Sequence to Function. Structure to Function**

GS.TS. Đỗ Phúc, 2024

66

Phát triển nghiên cứu ngành sinh tin học

- Theo chiều rộng sẽ bao gồm các phương pháp so sánh gen này với gen khác, protein này với protein khác.
- Ban đầu là những giải thuật đơn giản được dùng để so sánh chuỗi và cấu trúc của cặp protein liên quan. Khi dữ liệu sinh học gia tăng mạnh mẽ sẽ phát sinh nhu cầu cải tiến các thuật giải có hiệu suất cao để giống cột nhiều trình tự, trích rút mẫu chuỗi hay mẫu cấu trúc xác định họ protein, tạo cây phát sinh loài để khảo sát quá trình tiến hoá của protein.
- Cuối cùng, do thông tin được lưu trong CSDL lớn, công việc so sánh trở nên phức tạp hơn, đòi hỏi nhiều cải tiến trong cơ chế tổ chức và quản lý CSDL.

GS.TS. Đỗ Phúc, 2024

67

Các kỹ thuật Tin học trong sinh tin học

- Cơ sở dữ liệu
 - Building, Querying
 - Object DB
- So sánh chuỗi văn bản
 - Text Search
 - 1D Alignment
 - Significance Statistics
 - Google, grep
- Tìm mẫu
 - AI / Machine Learning
 - Clustering
 - Datamining
- Hình học
 - Robotics
 - Graphics (Surfaces, Volumes)
 - Comparison and 3D Matching (Vision, recognition)
- Mô phỏng vật lý
 - Newtonian Mechanics
 - Electrostatics
 - Numerical Algorithms
 - Simulation

GS.TS. Đỗ Phúc, 2024

68

Hidden Markov Models

- Mô hình Markov ẩn (Hidden Markov Model - HMM) là một mô hình thống kê sử dụng để mô hình hóa chuỗi dữ liệu có tính chất Markov, trong đó trạng thái hiện tại chỉ phụ thuộc vào trạng thái trước đó một cách xác định.
- Sự khác biệt chính giữa HMM và mô hình Markov "thông thường" là trạng thái hiện tại không thể quan sát được trực tiếp, mà chỉ có thể quan sát được thông qua một tập hợp các ký hiệu hoặc "trạng thái quan sát được" mà nó tạo ra.

GS.TS. Đỗ Phúc, 2024

69

Hidden Markov Model

HMMs thường được sử dụng trong nhiều lĩnh vực, bao gồm xử lý ngôn ngữ tự nhiên, nhận dạng giọng nói, nhận dạng từ vựng, sinh tin học (như dự đoán cấu trúc protein), và nhiều ứng dụng khác đòi hỏi mô hình hóa chuỗi dữ liệu. Trong HMM, các thông số quan trọng bao gồm ma trận chuyển đổi xác suất giữa các trạng thái ẩn, ma trận xác suất quan sát được từ mỗi trạng thái ẩn, và điều kiện ban đầu của các trạng thái ẩn.




GS.TS. Đỗ Phúc, 2024

70

Sinh tin học – đường hướng mới cho khoa học tính toán


Vật lý

- Dự báo dựa trên các nguyên tắc vật lý
- Vd: Ấn định chính xác quỹ đạo của hóa tiễn
- Nhấn mạnh: Siêu máy tính, CPU



Sinh học

- Phân loại thông tin và khác phá các quan hệ không mong đợi
- Vd: mạng biểu diễn Gene
- Nhấn mạnh: mạng CSDL "lên bang"



GS.TS. Đỗ Phúc, 2024

71

Chủ đề nghiên cứu về hệ gene

- Tìm Genes in trong chuỗi DNA của hệ gen
 - introns
 - exons
 - promotors
- Lập lại các đặc trưng trong hệ gen
 - Statistics
 - Patterns
- Nhân đôi của hệ gene
 - Large scale genomic alignment



GS.TS. Đỗ Phúc, 2024

72

Các chủ đề Sinh tin học, Chuỗi Protein

- Giống cột trình tự (sequence alignment)
 - Số khớp chuỗi gần đúng, các khoảng trống
 - Giống hai chuỗi một cách tối ưu thông qua Lập trình Động
 - Giống chuỗi Cục bộ và Toàn cục
 - Giống tối ưu phụ
 - Sử dụng hàm băm để tăng tốc độ (BLAST, FASTA)
 - Mã trận điểm thay thế axit amin
- Đa giống cột (multi sequence alignment) và mẫu bảo tồn (Consensus Patterns)
 - Giống cột nhiều chuỗi và sau đó kết hợp kết quả trong một mẫu bảo tồn
 - Số sánh chuyển tiếp
 - HMMs, Profiles
- Lược đồ điểm và thống kê khớp
 - Ý nghĩa thống kê của một phép giống cột
 - P-value (hay e-value)?
 - Điểm phân phối
 - Các chuỗi có độ phức tạp thấp
- Vấn đề tiến hóa (evolutionary Issues)
 - Tỉ lệ đột biến và thay đổi

GS.TS. Đỗ Phúc, 2024

73

Các chủ đề Chuỗi/ Cấu trúc protein

- Dự đoán "Cấu trúc" bậc 2
 - Xu hướng Hwang neural
 - Thuật toán Gen
 - Thống kê đơn giản
 - Tin kiểm vòng TM-helix
 - Đánh giá dự đoán Cấu trúc bậc 2
- Dự đoán cấu trúc: Protein v RNA
- Dự đoán cấu trúc bậc 3
 - Nhận dạng nếp gấp
 - Threading
 - Ab initio
- Dự báo chức năng
 - Nhận dạng site hoạt động
- Quan hệ giữa tương đồng cấu trúc và tương đồng chức năng

GS.TS. Đỗ Phúc, 2024

74

Graph Database of Protein Structure (Do Phuc, NTK Phung, 2008)



GS.TS. Đỗ Phúc, 2024

75

Các chủ đề về hệ gene


- Phân tích biểu hiện
 - Time Courses clustering
 - Đo sự khác biệt
 - Nhận dạng vùng điều hòa
- Tổ chức lại thông tin theo quy mô lớn bằng cách tham khảo chéo
- Phân loại chức năng và các gen đồng vị
- Quan điểm về Genomic so với Đơn phân tử
- So sánh hệ Genome
 - Các họ ortholog, pathway
 - Các cuộc điều tra quy mô lớn
 - Phân tích tử vong thường xuyên
 - Chỉ thích Genomic
 - Cây phát sinh từ Genomes
 - Xác định các protein tương tác
- Structural Genomics
 - Nếp gấp trong hệ gene, chia sẻ các nếp gấp chung
 - Dự báo cấu trúc tổng thể
- Genome Trees

GS.TS. Đỗ Phúc, 2024

76

Ứng dụng kỹ thuật tin học

- Nhiều lĩnh vực Sinh Tin học đòi hỏi các kỹ thuật tin học khác nhau như: Tổ chức và quản lý CSDL
- Tuy nhiên khi gia tăng số lượng thông tin, các CSDL quan hệ với giao diện Web sẽ ngày càng phổ biến, những kỹ thuật mới cần phát triển bao gồm phương pháp so sánh chuỗi, giải thuật giống cột, nhận diện đoạn lặp (motif) và các phương pháp học máy, phân cụm và kỹ thuật khai thác dữ liệu.
- Phân tích cấu trúc 3D bao gồm tính toán hình học Euclid kết hợp với ứng dụng cơ bản của hóa lý, thể hiện đồ họa của bề mặt và hình khối, và sự so sánh cấu trúc và phương pháp hợp 3D.



GS.TS. Đỗ Phúc, 2024

77

Vài phần mềm Sinh Tin học

GS.TS. Đỗ Phúc, 2024

78

Vài phần mềm Sinh Tin học

- **BLAST (Basic Local Alignment Search Tool):** Sử dụng để so sánh thông tin chuỗi sinh học cơ bản, như các chuỗi amino axit của các protein khác nhau hoặc các nucleotides của các chuỗi DNA.
- **Clustal Omega:** Một chương trình căn chỉnh nhiều chuỗi cho các protein và chuỗi nucleotide.
- **UCSC Genome Browser:** Một nền tảng được sử dụng rộng rãi để hiển thị và phân tích dữ liệu genomic.
- **NCBI Entrez Utilities:** Một bộ công cụ cho việc tìm kiếm, truy xuất và phân tích dữ liệu sinh học từ các cơ sở dữ liệu của Trung tâm Thông tin Sinh học Phân tử (NCBI).
- **EMBOSS:** Bộ công cụ phần mềm mở cho các phân tích sinh học phân tử, cung cấp hơn 200 công cụ cho nghiên cứu sinh học phân tử.
- **FASTX-Toolkit:** Một bộ công cụ dòng lệnh cho việc tiền xử lý các tệp FASTA/FASTQ của đọc ngắn.

GS.TS. Đỗ Phúc, 2024

79

Vài phần mềm Sinh Tin học

- **Biopython/BioPerl/BioRuby:** Đây là các thư viện cho các ngôn ngữ lập trình Python, Perl và Ruby tương ứng, cung cấp các công cụ cho tính toán sinh học.
- **MOE (Molecular Operating Environment):** Một hệ thống phần mềm toàn diện cho thiết kế, mô phỏng và phân tích phân tử trong phát hiện thuốc và khoa học vật liệu.
- **Rosalind:** Một nền tảng để học bioinformatics thông qua các thách thức giải quyết vấn đề.
- **PhyML:** Một gói phần mềm cho phân tích phylogenetic của các chuỗi phân tử.

GS.TS. Đỗ Phúc, 2024

80

Phần mềm Modeller

- Modeller là một phần mềm dùng để dự đoán cấu trúc protein và mô hình hóa phân tử. Được sử dụng rộng rãi trong nghiên cứu sinh học cấu trúc và thiết kế được phẩm, Modeller cung cấp các công cụ để tạo ra các mô hình cấu trúc protein dựa trên thông tin chuỗi protein đầu vào và các mô hình tham chiếu. Đây là một công cụ quan trọng cho việc nghiên cứu về cấu trúc và chức năng của protein, cũng như trong các dự án thiết kế phân tử.
- Cụ thể, Modeller có thể được sử dụng cho các mục đích như:
 1. **Dự đoán cấu trúc protein:** Xây dựng mô hình 3D cho các protein dựa trên thông tin chuỗi amino axit.
 2. **Thiết kế protein:** Tạo ra các biến thể protein có tính chất đặc biệt như khả năng kết hợp với các phân tử khác hoặc ổn định hơn.
 3. **Dự đoán cấu trúc liên quan đến protein:** Bao gồm dự đoán liên kết protein-protein và protein-ligand.
 4. **Docking phân tử:** Dự đoán cấu trúc phức hợp protein-liên kết với các phân tử khác.
 5. **Nghiên cứu động học protein:** Xem xét các chuyển động và biến dạng của protein theo thời gian.

GS.TS. Đỗ Phúc, 2024

81

Dù có nhiều phần mềm Bioinformatics đã tồn tại và được sử dụng rộng rãi, nhưng vẫn có nhiều lý do mà cần phải viết thêm các phần mềm mới:


1. **Yêu cầu Cụ thể:** Mỗi dự án hoặc nghiên cứu trong lĩnh vực sinh học có thể có yêu cầu cụ thể không được đáp ứng bởi các phần mềm hiện có.
2. **Phát triển Công nghệ:** Công nghệ trong lĩnh vực Bioinformatics tiếp tục phát triển, đặc biệt là trong lĩnh vực sequencing và phân tích dữ liệu lớn. Việc viết các phần mềm mới có thể giúp khai thác những tiến bộ mới này và tạo ra công cụ tốt.
3. **Hiệu suất và Tối ưu hóa:** Các phần mềm mới có thể được tối ưu hóa cho hiệu suất hoặc tài nguyên máy tính cụ thể, giúp tăng cường hiệu suất tính toán và giảm thời gian xử lý.
4. **Sự Đa dạng trong Dữ liệu:** Dữ liệu sinh học có sự đa dạng rất lớn, từ chuỗi nucleotide đến dữ liệu hình ảnh và cấu trúc phân tử. Việc viết các phần mềm mới có thể tập trung vào việc xử lý loại dữ liệu mới để tích hợp dữ liệu từ nhiều nguồn khác nhau.
5. **Công cụ Tùy chỉnh:** Một số dự án cần các công cụ tùy chỉnh để giải quyết các vấn đề cụ thể của họ.
6. **Cộng đồng Mở rộng:** Việc phần mềm mới cũng để mở rộng cộng đồng, thu hút thêm người dùng và nhà phát triển mới để đóng góp vào dự án và cải thiện sản phẩm.

GS.TS. Đỗ Phúc, 2024

82

Trí tuệ nhân tạo là gì? AI- Artificial Intelligence

Trí tuệ nhân tạo trong Sinh Tin học



AI in bioinformatics | AI in biology | AI

GS.TS. Đỗ Phúc, 2024

83

GS.TS. Đỗ Phúc, 2024

84

Vài nét về trí tuệ nhân tạo

- Trí tuệ nhân tạo (AI) bao gồm các **phương pháp mô phỏng trí thông minh của con người** trong đó bao gồm các hoạt động học, nhận thức và ra quyết định.
- Khi bàn về AI, ta có thể dùng các thuật ngữ như khoa học về nhận thức, sự thông minh của máy, học máy và học sâu



GS.TS. Đỗ Phúc, 2024

85

Vài nét về trí tuệ nhân tạo

Các giải pháp này kết hợp các công nghệ khác nhau tương tác với các dịch vụ như:

- Học máy** - là khả năng của phần mềm giúp học hỏi từ phân tích dữ liệu và tạo ra mô hình thực hiện một nhiệm vụ
- Khoa học dữ liệu** - thu thập, xử lý và phân tích một lượng lớn dữ liệu
- Kết nối vạn vật (IoT)** - bao gồm các thiết bị kết nối đa dạng được sử dụng để thu thập và truyền dữ liệu.




GS.TS. Đỗ Phúc, 2024

86

THE BRANCHES OF ARTIFICIAL INTELLIGENCE

biotechnika



Một số nhánh quan trọng của AI

- Học máy (Machine Learning - ML):** Học máy là một phần quan trọng của AI, nơi máy tính được huấn luyện để hiểu và thực hiện các nhiệm vụ mà không cần được lập trình một cách cụ thể. Các thuật toán học máy bao gồm học giám sát, học không giám sát và học tăng cường.
- Học sâu (Deep Learning):** Là một phần của học máy, học sâu sử dụng các mô hình nơ-ron sâu để hiểu và đại diện cho dữ liệu phức tạp. Mạng nơ-ron sâu, như mạng nơ-ron thần kinh (NNN) và các kiến trúc khác, thường được sử dụng trong học sâu.
- Thị giác máy tính (Computer Vision):** Tập trung vào việc làm cho máy tính có khả năng "nhìn" và hiểu hình ảnh và video. Các ứng dụng bao gồm nhận diện đối tượng, nhận diện khuôn mặt và xử lý hình ảnh y tế.
- Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP):** Tập trung vào việc giúp máy tính hiểu, tạo ra và tương tác với ngôn ngữ tự nhiên của con người. Bao gồm các nhiệm vụ như dịch ngôn ngữ, phân loại văn bản và tóm tắt văn bản.

GS.TS. Đỗ Phúc, 2024

88

Một số nhánh quan trọng của AI

- Robotics:** Kết hợp AI và cơ học để tạo ra robot có khả năng thực hiện nhiều nhiệm vụ khác nhau, từ sản xuất công nghiệp đến dịch vụ và chăm sóc sức khỏe.
- Thực tế ảo và thực tế ảo tăng cường (Virtual Reality - VR và Augmented Reality - AR):** Sử dụng công nghệ AI để tạo ra trải nghiệm tương tác ảo và mở rộng thế giới thực với thông tin số hóa.
- Hệ thống thông minh (Intelligent Systems):** Bao gồm phát triển hệ thống thông minh có khả năng tự động và tương tác thông minh với môi trường xung quanh.
- Học tăng cường (Reinforcement Learning):** Học tăng cường là một dạng của học máy, trong đó máy tính học từ trải nghiệm và áp dụng kiến thức này để đưa ra quyết định tối ưu trong môi trường.
- Mạng nơ-ron đồ thị (Graph Neural Networks):** Tập trung vào phân tích và hiểu thông tin được biểu diễn dưới dạng đồ thị, như mạng xã hội hoặc các mạng phức tạp khác.

GS.TS. Đỗ Phúc, 2024

89

Tại sao dùng AI trong bioinformatics

Sử dụng Trí tuệ Nhân tạo (AI) trong lĩnh vực Sinh học Tin học (Bioinformatics) mang lại nhiều lợi ích do tính đặc biệt và phức tạp của dữ liệu sinh học. Dưới đây là một số lý do chính:

- Xử lý dữ liệu lớn và phức tạp:** Dữ liệu sinh học thường rất lớn và phức tạp, bao gồm thông tin từ nhiều nguồn khác nhau như genomics, proteomics, metabolomics, và hình ảnh y học. AI có khả năng xử lý dữ liệu lớn và phức tạp một cách hiệu quả, giúp trích xuất thông tin quan trọng từ dữ liệu rối bời và đồng thời tìm ra mối quan hệ phức tạp giữa các yếu tố khác nhau.
- Dự đoán và phân loại:** Các thuật toán máy học có thể được sử dụng để dự đoán kết quả của các thí nghiệm sinh học, như dự đoán cấu trúc protein, phân loại bệnh lý, hoặc đặc điểm geneticalinh.
- Khám phá tri thức mới:** AI có khả năng khám phá mối quan hệ phức tạp trong dữ liệu, giúp nhà nghiên cứu sinh học phát hiện ra những tri thức mới về mối liên kết giữa gen, protein, và các quá trình sinh học khác.

GS.TS. Đỗ Phúc, 2024

90

Tại sao dùng AI trong bioinformatics

- 4. **Tìm kiếm dựa trên đặc trưng:** AI có thể giúp tìm kiếm dựa trên đặc trưng của dữ liệu, giúp nhận biết gen, protein hay các cấu trúc sinh học quan trọng.
- 5. **Tăng cường đối với công việc phân tích và giải mã dữ liệu genomics:** Trong lĩnh vực genomics, AI có thể hỗ trợ trong công việc giải mã chuỗi gen và xác định các biểu hiện gen, giúp nhà nghiên cứu hiểu rõ hơn về các quy luật di truyền và tác động của gen đối với sức khỏe.
- 6. **Tối ưu hóa quá trình nghiên cứu:** AI có thể giúp tối ưu hóa quá trình nghiên cứu, từ việc lựa chọn thử nghiệm đến phân tích dữ liệu, giảm thời gian và chi phí.
- Tóm lại, sử dụng AI trong bioinformatics mang lại sự mạnh mẽ trong việc xử lý và hiểu biết dữ liệu sinh học, đồng thời cung cấp những công cụ mạnh mẽ để nghiên cứu và áp dụng kiến thức sinh học vào y học và các lĩnh vực khác.

GS.TS. Đỗ Phúc, 2024

91

Hệ chuyên gia Expert System

GS.TS. Đỗ Phúc, 2024

92

Hệ chuyên gia là gì?

- Hệ chuyên gia là một loại hệ cơ sở tri thức được thiết kế cho một lĩnh vực ứng dụng cụ thể.
- Ví dụ: Hệ chuyên gia đánh giá tín dụng trong ngân hàng
- Các hệ chuyên gia làm việc như một chuyên gia thực thụ




GS.TS. Đỗ Phúc, 2024

93

Hệ chuyên gia là gì?

- Cơ sở tri thức** là nơi lưu trữ biểu diễn các tri thức mà hệ đảm nhận, làm cơ sở cho các hoạt động của hệ. Cơ sở tri thức bao gồm các sự kiện và các luật.
- Động cơ suy diễn:** là quá trình trong hệ chuyên gia cho phép khớp các sự kiện trong vùng nhớ làm việc với các tri thức về các lĩnh vực trong cơ sở tri thức, để rút ra các kết luận về các vấn đề đang giải quyết.




GS.TS. Đỗ Phúc, 2024

94

Học máy Machine learning

Học máy

- Học máy (machine learning)** là một lĩnh vực của AI liên quan đến việc nghiên cứu và xây dựng các kỹ thuật cho phép các hệ thống "**học**" từ dữ liệu để giải quyết những vấn đề cụ thể.



GS.TS. Đỗ Phúc, 2024

95

GS.TS. Đỗ Phúc, 2024

96

Nơron sinh học, neuron nhân tạo

- Các nơron nối với nhau ở các synapses. Synapse được gọi là mạch, khi nó cho phép truyền dẫn dễ dàng tín hiệu qua các nơron khác.
- Nơron sẽ lấy input thứ nhất, nhân với weight trên đường input thứ nhất, lấy input thứ hai nhân với weight của đường input thứ hai v.v..., rồi lấy tổng của tất cả các kết quả thu được. Sau đó so với ngưỡng để có đầu ra



GS.TS. Đỗ Phúc, 2024


103

Mạng nơron nhiều lớp

Tầng vào (input layer): cho các đầu vào của mạng.

Tầng ra (output layer): cho các đầu ra của mạng.

Tầng ẩn (hidden layer): Là tầng nằm giữa tầng vào và tầng ra thể hiện cho việc suy luận logic của




GS.TS. Đỗ Phúc, 2024

104

Huấn luyện mạng nơron

- Thuật toán lan truyền ngược (back propagation)
- Cung cấp tập dữ liệu học
- Tiêu chuẩn huấn luyện: Làm cho sai số đầu ra càng nhỏ càng tốt.
- Triết lý của phương pháp: **dựa trên đầu ra để điều chỉnh trọng số của lớp ra**, sau đó dựa trên tính toán của lớp ra để điều chỉnh trọng số của lớp ẩn.




GS.TS. Đỗ Phúc, 2024

105

Học sâu Deep Learning

Học sâu- deep learning

- Học sâu** là một hướng nghiên cứu phát triển của học máy dựa trên một tập hợp các thuật toán để cố gắng mô hình dữ liệu trừu tượng hóa ở mức cao bằng cách sử dụng **nhiều lớp xử lý** với cấu trúc phức tạp nhiều tầng.
- Dữ liệu huấn luyện rất lớn
- Cuộc cách mạng về phân tích dữ liệu



GS.TS. Đỗ Phúc, 2024

107

Xử lý ngôn ngữ tự nhiên Natural Language Processing

GS.TS. Đỗ Phúc, 2024

109

Xử lý ngôn ngữ tự nhiên (NLP)

- NLP là viết tắt của "Natural Language Processing" trong tiếng Anh
- NLP là một lĩnh vực trong lĩnh vực trí tuệ nhân tạo (AI) tập trung vào tương tác giữa máy tính và ngôn ngữ tự nhiên của con người.
- Mục tiêu chính của NLP là giúp máy tính hiểu, hiểu và tương tác với ngôn ngữ một cách tự nhiên, giống như cách con người làm.
- Các kỹ thuật và mô hình học máy, đặc biệt là mô hình ngôn ngữ có sức mạnh lớn như GPT (Generative Pre-trained Transformer), đã giúp đẩy mạnh phát triển của lĩnh vực này.



GS.TS. Đỗ Phúc, 2024

110

Các tác vụ chính của NLP

- Phân loại văn bản (Text Classification):** Xác định loại hoặc chủ đề của một đoạn văn bản, ví dụ như phân loại email là spam hay không.
- Dịch ngôn ngữ (Machine Translation):** Chuyển đổi văn bản từ một ngôn ngữ sang ngôn ngữ khác.
- Phân tích ý định (Intent Analysis):** Xác định ý định hoặc mục tiêu của người nói trong một đoạn văn bản hoặc lời nói.
- Tìm kiếm thông tin (Information Retrieval):** Trích xuất thông tin quan trọng từ văn bản hoặc tìm kiếm thông tin trong tập dữ liệu lớn.
- Tóm tắt văn bản (Text Summarization):** Tạo bản tóm tắt ngắn gọn từ một đoạn văn bản dài.
- Phân tích cảm xúc (Sentiment Analysis):** Xác định và đánh giá cảm xúc (tích cực, tiêu cực, hoặc trung lập) từ ngôn ngữ.



GS.TS. Đỗ Phúc, 2024

111

Các tác vụ chính của NLP

- Xác định thực thể (Named Entity Recognition - NER):** Nhận diện và phân loại các thực thể như tên người, địa điểm, tổ chức trong văn bản.
- Hiểu ngôn ngữ tự nhiên (Natural Language Understanding - NLU):** Hiểu ý nghĩa của văn bản và tương tác với người dùng dựa trên ngôn ngữ tự nhiên.
- Tạo văn bản tự động (Text Generation):** Tạo ra văn bản mới dựa trên mô hình học máy đã được huấn luyện.
- Đối thoại (Chatbot):** Tạo và duy trì cuộc trò chuyện với người dùng thông qua ngôn ngữ tự nhiên.
- Nhận diện ngôn ngữ (Language Identification):** Xác định ngôn ngữ của một đoạn văn bản.
- Phân loại ngôn ngữ của văn bản (Language Detection):** Xác định ngôn ngữ mà văn bản đang sử dụng.



GS.TS. Đỗ Phúc, 2024



112

Video Clip: AI in bioinformatics



GS.TS. Đỗ Phúc, 2024

113



Machine learning for drug discovery

Quantitative Structure-Activity Relationship

biotechnip

biotechnip

Computer Aided Drug Design

Protein-Ligand Interaction

Tong Zhu
State key laboratory of precision spectroscopy
East China Normal University
2014-12-05
GS.TS. Đỗ Phúc, 2024

118

Ứng dụng : Thiết kế thuốc (Designing Drugs)

Cor

- Hiểu cách các cấu trúc kết nối các phần tử khác (Chức năng)
- Thiết kế chất ức chế
- Docking (neo), Mô hình hóa cấu trúc

(Từ trái sang phải, các hình được điều chỉnh từ Trang Docking của Nhóm Olsen tại Scripps, Trang Web của Nhóm NMR Dyson tại Scripps, và từ Trang Hóa học Tính toán tại Trung tâm Lý thuyết Cornell).

GS.TS. Đỗ Phúc, 2024

119

Cách làm việc của thuốc

Thuốc: Một chất được sử dụng trong việc chẩn đoán, điều trị, hoặc ngăn chặn một bệnh, hoặc là một thành phần của một loại thuốc.

Lock-and-key model

GS.TS. Đỗ Phúc, 2024

120

Tiến trình phát triển thuốc

Tìm hợp chất chống lại Protein gây bệnh

Bệnh

Hit ID (2-5 years)

Hit to Lead (2-5 years)

Hỗ trợ IND
Độc tính đối với động vật

Sự chấp nhận của FDA

Tìm hợp chất chống lại Protein gây bệnh (2-5 years)

Thử nghiệm tiền lâm sàng
Hiệu suất dài với động vật
Tối ưu hóa dẫn đầu (1-3 years)

Thử nghiệm lâm sàng trên người
Phase 1
Phase 2
Phase 3
(2-10 years)

GS.TS. Đỗ Phúc, 2024

121


20

Tiến trình phát triển thuốc

Bạn phải kiểm thử **RẤT NHIỀU** hợp chất để tìm ra một loại thuốc.


10 – 15 years,

500 - 1000 million US \$



122

Tại sao dùng CADD ?



- ✓ Xác định Hit
- ✓ Chọn lọc leads
- ✓ Tối ưu hóa dẫn đầu

- Giảm chi phí/thời gian
- Giảm số lượng động vật được sử dụng trong thí nghiệm
- Nâng cao tỷ lệ thành công
- Nâng cao hiểu biết về tương tác giữa thuốc và protein


Tiết kiệm 2 – 5 years, 100 - 500 million US \$

GS.TS. Đỗ Phúc, 2024

123

Xác định cấu trúc 3D

- Nguyên lý: Dùng phần mềm dự đoán cấu trúc 3D của protein mục tiêu dựa trên cấu trúc 3D đã biết của protein mẫu
- Công cụ: Phần mềm Modeller




GS.TS. Đỗ Phúc, 2024

124

Sự tương đồng


- Tìm kiếm các chất tương tự thuốc.
- Nguyên lý: Từ một hợp chất ứng viên (lead compound). Tìm kiếm các hợp chất hóa học có cấu trúc hay đặc điểm tương tự với hợp chất đã biết
- Phương pháp:
- Trình tự tương đồng 3D, 2D



GS.TS. Đỗ Phúc, 2024

125


Thiết kế thuốc dựa trên cấu trúc



Experiment or sequence

Ligand là một phân tử hoặc ion có khả năng kết hợp với một nguyên tử hoặc phân tử khác để tạo thành một phức hợp

Modeller
Discovery studio
...





Binding pocket

GS.TS. Đỗ Phúc, 2024

126

Thiết kế thuốc dựa trên cấu trúc

Dockey: Tìm sự kết hợp "tốt nhất" giữa protein mục tiêu và ứng cử viên thuốc.



$$E_{\text{dock}} = E_{\text{elec}} + E_{\text{vdw}} + E_{\text{hydrophobic}} + E_{\text{hydrogen}}$$

$$= \sum_{\text{pairs atoms}} \left[\frac{q_i q_j}{|d_{ij}|} + \frac{R_{ij}}{d_{ij}^6} \right] + \sum_{\text{pairs atoms}} B(i) + \sum_{\text{pairs atoms}} \left[\frac{C_{ij}}{|d_{ij}|^6} + \frac{D_{ij}}{d_{ij}^{12}} \right] + \sum_{\text{pairs atoms}} 332.0 \frac{q_i q_j}{|d_{ij}|} + \sum_{\text{pairs atoms}} \left[\frac{C_{ij}}{|d_{ij}|^6} + \frac{D_{ij}}{d_{ij}^{12}} \right] + \sum_{\text{pairs atoms}} 332.0 \frac{q_i q_j}{|d_{ij}|} + \sum_{\text{pairs atoms}} \left[\frac{C_{ij}}{|d_{ij}|^6} + \frac{D_{ij}}{d_{ij}^{12}} \right]$$

Autodock
Glide
Sybyl
MOE


GS.TS. Đỗ Phúc, 2024

127

Các bước của quá trình mô phỏng

- Quá trình mô phỏng thường đi qua các bước sau:

 - 1. Xác định mục tiêu:** Đầu tiên, bạn cần xác định rõ mục tiêu của việc mô phỏng. Điều này giúp bạn quyết định mức độ chi tiết của mô hình và các dữ liệu cần thu thập.
 - 2. Thu thập dữ liệu:** Tiếp theo, bạn cần thu thập dữ liệu về các thành phần của hệ thống, bao gồm các tham số vật lý, hóa học, hoặc sinh học.
 - 3. Xây dựng mô hình:** Sau khi có đủ dữ liệu, bạn cần xây dựng mô hình toán học hoặc mô hình máy tính để mô phỏng hành vi của hệ thống.
 - 4. Kiểm tra và xác minh:** Trước khi chạy mô phỏng, bạn cần kiểm tra mô hình để đảm bảo rằng nó phản ánh đúng thực tế và rằng các tham số đã được nhập chính xác.
 - 5. Chạy mô phỏng và phân tích kết quả:** Sau khi đã kiểm tra mô hình, bạn có thể chạy mô phỏng và phân tích kết quả. Điều này có thể bao gồm việc so sánh kết quả mô phỏng với dữ liệu thực nghiệm.
 - 6. Đánh giá và cải thiện:** Cuối cùng, bạn cần đánh giá kết quả mô phỏng và quyết định xem có cần cải thiện mô hình hay không.



Dùng trí tuệ nhân tạo (AI) để mô phỏng

- Sau đây là một số cách sử dụng AI để mô phỏng:

- 1. Mô hình học máy:** Sử dụng các mô hình học máy để tạo ra một biểu diễn của hệ thống hoặc quy trình dựa trên dữ liệu. Các mô hình này có thể được huấn luyện để hiểu và dự đoán hành vi của hệ thống trong các điều kiện khác nhau.
 - 2. Mô phỏng tương tự:** Sử dụng các thuật toán học tăng cường để tạo ra một môi trường mô phỏng, trong đó các tác nhân AI có thể tương tác với nhau và với môi trường. Điều này có thể hữu ích để mô phỏng các hệ thống phức tạp như giao thông đô thị, kinh doanh, hoặc thậm chí là sinh thái học.
 - 3. Mô phỏng tối ưu hóa:** Sử dụng các thuật toán tối ưu hóa AI để tối ưu hóa hoặc cải thiện hiệu suất của hệ thống trong một môi trường mô phỏng. Điều này có thể bao gồm tối ưu hóa kế hoạch sản xuất, quản lý chuỗi cung ứng, hoặc tối ưu hóa mạng lưới giao thông.
 - 4. Hệ thống thông minh tự động hóa:** Sử dụng AI để xây dựng các hệ thống tự động hóa có khả năng tự động thích ứng và điều chỉnh trong môi trường mô phỏng. Điều này có thể bao gồm việc xây dựng các hệ thống tự lái, hệ thống điều khiển tự động, hoặc hệ thống quản lý tự động.
- Dùng AI trong mô phỏng có thể cung cấp các biểu diễn chính xác hơn và phức tạp hơn về hệ thống hoặc quy trình so với các phương pháp truyền thống, giúp bạn hiểu rõ hơn về hành vi và hiệu suất của chúng trong các điều kiện khác nhau.


Mô phỏng tế bào nhân tạo (Artificial Cell Simulation)

- Mục tiêu của mô phỏng này thường là hiểu và dự đoán các khía cạnh của sự sống và sự tự tổ chức của các hệ thống tế bào.
- Dưới đây là một số ứng dụng và phương pháp trong mô phỏng tế bào nhân tạo:

 - 1. Hệ thống tế bào đơn giản:** Xây dựng mô hình tính toán của các tế bào cơ bản như tế bào vi khuẩn hoặc tế bào thực vật. Các mô hình này thường dựa trên các phương trình toán học để mô tả các quá trình sinh học cơ bản như trao đổi chất, phân tử hóa và tương tác giữa các bộ phận trong tế bào.
 - 2. Mạng lưới tín hiệu phân tử:** Xây dựng các mô hình mạng lưới phức tạp của các tế bào nhân tạo để nghiên cứu về mô phỏng các quá trình sinh học phức tạp như tương tác gen, tương tác protein-protein và các hệ thống điều khiển trong tế bào.
 - 3. Mô phỏng tế bào thực vật và động vật:** Tạo ra các mô hình của các hệ thống tế bào thực vật và động vật để nghiên cứu và dự đoán hành vi của chúng trong các điều kiện khác nhau, từ môi trường nước đến môi trường không khí.
 - 4. Tính toán sinh học (Computational Biology):** Sử dụng các phương pháp tính toán để mô phỏng và dự đoán các quá trình sinh học phức tạp như phát triển và tiến hóa của các loài, và để hiểu các căn bệnh và cơ chế của chúng.

 - Mô phỏng tế bào nhân tạo cung cấp một cách tiếp cận mạnh mẽ để nghiên cứu và hiểu sâu hơn về các quá trình sinh học cơ bản và phức tạp, và có thể đóng vai trò quan trọng trong việc phát triển các ứng dụng trong lĩnh vực y học, sinh học, và công nghệ sinh học.

Mô phỏng tế bào nhân tạo



GS.TS. Đỗ Phúc, 2024

137

Hạ tầng tính toán mạnh cho các giải thuật phân tích dữ liệu Sinh tin học



GS.TS. Đỗ Phúc, 2024

138

GS.TS. Đỗ Phúc, 2024

Xử lý dữ liệu lớn Tính toán phân tán



GLOBAL JOURNAL OF COMPUTER SCIENCE AND TECHNOLOGY: A
HARDWARE & COMPUTATION
Volume 14 Issue 1, Winter 1, 05 Nov 2024
Topic: Distributed Bioinformatics Computing System for DNA Sequence
Publication: Global Journals Inc. (USA)
Online Issue: 0973-4122 & Print Issue: 0973-4320

Distributed Bioinformatics Computing System for DNA Sequence Analysis

By Mohammad Ibrahim Khan, Kaushik Deb & Chetan Shree


Abstract: This paper provides an effective design of a distributed bioinformatics computing system for analysis of DNA sequences using OPTSNA algorithm. The system can be used for detecting different types of distributed algorithms for the search and identification for DNA sequences and repeat pattern in a given DNA sequence are developed. The search algorithm was developed to compute the number of DNA sequence which contains the same consecutive types of DNA sequences. A distributed subsequence identification algorithm was designed and implemented to detect the segment containing DNA sequences. Sequential and distributed implementation of these algorithms was executed with different lengths of search segments patterns and genomic sequences. OPTSNA algorithm is used for sharing various nodes of DNA sequence into database. DNA sequences of different lengths were tested by using this algorithm. These input DNA sequences varied in size from very small to very large. The performance of search technique distributed system is compared with sequential approach.

Keywords: distributed bioinformatics system, DNA sequence, search segments, identify DNA sequences, reported gene sequences.

DOI:10.24015/GJCST.14.1.1

Giới thiệu Hadoop


- Hadoop là một framework nguồn mở viết bằng Java dùng để chạy những ứng dụng trên 1 cluster lớn được xây dựng trên những phần cứng thông thường.
- Hadoop hiện thực mô hình Map/Reduce chia nhỏ ra thành nhiều phần đoạn, chạy song song trên nhiều node khác nhau.
- Cho phép các ứng dụng có thể làm việc với hàng ngàn node khác nhau và hàng petabyte dữ liệu.
- Hadoop cho phép phát triển các ứng dụng phân tán bằng java, scala, python và một số ngôn ngữ lập trình khác
- Hadoop giải pháp cho SME để xử lý big data



GS.TS. Đỗ Phúc, 2024

140

Map Reduce



Mapreduce Example in Apache Hadoop...

MapReduce: phân tán dữ liệu, xử lý ra nhiều máy

GS.TS. Đỗ Phúc, 2024

141

Apache Spark xử lý dữ liệu lớn trong bộ nhớ

- Hệ thống tính toán cụm nhanh, tương thích với Apache Hadoop
- Làm việc với bất kỳ hệ thống lưu trữ phân tán được Hadoop hỗ trợ (HDFS, S3, Avro,...)
- Cải thiện hiệu quả thông qua: Nguyên tắc tính toán trong bộ nhớ
- Các thư viện MLlib, GraphX, SQL, Stream




GS.TS. Đỗ Phúc, 2024

142

Spark cluster

- Load error messages from a log into memory, then interactively search for patterns



GS.TS. Đỗ Phúc, 2024

143

Siêu máy chủ Nvidia của UIT, 2024

Siêu máy chủ này là hệ thống phổ quát cho tất cả cơ sở hạ tầng AI, từ phân tích (analytics), đào tạo (training) đến suy luận (inference). Máy đóng gói mật độ cao các computer với hiệu suất xử lý AI lên đến 5 petaFLOPS trong một khung máy 6U, thay thế một tháp cơ sở hạ tầng chỉ bằng một nền tảng cho mọi AI workload. Đây là một trong những siêu máy chủ mạnh của NVIDIA hiện nay.



Siêu máy chủ NVIDIA DGX A100 tại trường Đại học Công nghệ thông tin - Anh - Mỹ

GS.TS. Đỗ Phúc, 2024

144

NVIDIA DGX A100


- NVIDIA DGX A100 là một trong những máy tính siêu hiệu suất của NVIDIA, được thiết kế đặc biệt cho các ứng dụng trí tuệ nhân tạo (AI), học máy, và tính toán đám mây. Dưới đây là một số thông số kỹ thuật cơ bản của máy NVIDIA DGX A100:
- 1. **Bộ xử lý đồng trục NVIDIA A100 Tensor Core GPU:** Máy sử dụng GPU NVIDIA A100 Tensor Core, là công nghệ mạnh mẽ cho tính toán AI và tính toán khoa học.
- 2. **Cấu trúc hệ thống: DGX A100 có thể chứa nhiều GPU NVIDIA A100 trong một hệ thống.** Cấu hình thường đi kèm với nhiều GPU để tăng khả năng tính toán.
- 3. **Bộ nhớ GPU và Hệ thống:** DGX A100 được trang bị bộ nhớ GPU rất lớn, giúp cho việc xử lý dữ liệu lớn và các mô hình AI phức tạp. Hệ thống cũng có thể có bộ nhớ hệ thống lớn để hỗ trợ việc lưu trữ và truy cập dữ liệu.
- 4. **Tính linh hoạt:** DGX A100 thường đi kèm với các tính năng linh hoạt như khả năng kết nối mạng, tích hợp với các phần mềm quản lý hệ thống và tính bảo mật cao.
- 5. **Hiệu suất và Tính tiêu thụ năng lượng:** Máy có hiệu suất tính toán cao và thường được tối ưu hóa để tiêu thụ ít năng lượng nhất có thể, nhằm giảm thiểu chi phí vận hành và bảo vệ môi trường.

GS.TS. Đỗ Phúc, 2024

145

Top 5 applications of machine learning in bioinformatics

- 1. Hỗ trợ các thí nghiệm chỉnh sửa gene
 - 2. Xác định cấu trúc protein
 - 3. Phát hiện các gene liên quan đến các bệnh
 - 4. Duyệt qua cơ sở kiến thức để tìm kiếm các mô hình có ý nghĩa
 - 5. Tái sử dụng các loại thuốc
- (source: <https://itrexgroup.com/blog/ai-and-machine-learning-in-bioinformatics/>)




GS.TS. Đỗ Phúc, 2024

146

Ứng dụng của AI trong BioInformatics

- 1. Phân tích Genomics:**
 - Dự đoán Genes và Proteins: Các mô hình học máy có thể được sử dụng để dự đoán vị trí của gen và các protein liên quan dựa trên dữ liệu chuỗi gen.
 - So sánh Genomes: AI có thể giúp so sánh và phân tích sự tương đồng và khác biệt giữa các chuỗi gen để hiểu rõ hơn về tiến hóa và các biểu hiện gen.
- 2. Dự đoán Structured Biology**
 - Dự đoán Cấu trúc Protein: AI có thể giúp dự đoán cấu trúc protein, giúp định rõ chức năng và tương tác của chúng.
 - Mô hình hóa Động học Mạng Lưới: Sử dụng mô hình học máy để mô phỏng mạng lưới phức tạp của các phản ứng sinh học và động học protein.
- 3. Drug Discovery và Phát triển**
 - Mô hình Dự đoán Tương tác Thuốc-Protein: Ứng dụng AI để dự đoán tương tác giữa các phân tử thuốc và protein, giúp tăng tốc quá trình phát triển thuốc mới.
 - Tìm kiếm Mô quan hệ Thuốc-Gen: Xác định mối quan hệ giữa biểu hiện gen và phản ứng của thuốc để tối ưu hóa điều trị.



GS.TS. Đỗ Phúc, 2024

147

4. Biomedical Image Analysis:

- Phân đoạn và Nhận diện ảnh y khoa: Sử dụng học máy để phân loại và phân đoạn các cấu trúc trong ảnh y khoa, giúp chẩn đoán và điều trị bệnh lý.
- Dự đoán Tiến triển Bệnh: Sử dụng hình ảnh y khoa để dự đoán tiến triển của bệnh, giúp phát hiện sớm và quản lý bệnh lý.

5. Phân tích Dữ liệu Single-Cell:


- Phân loại Tế bào: AI có thể giúp phân loại và hiểu biểu hiện gen của từng tế bào, giúp hiểu rõ hơn về đa dạng tế bào và sự biến đổi trong các mô cụ thể.

6. Dự đoán Rủi ro Bệnh:

- Dự đoán Rủi ro Ung thư: Sử dụng mô hình học máy để dự đoán rủi ro phát triển ung thư dựa trên dữ liệu gen và y tế cá nhân.

7. Quản lý Dữ liệu Sinh học:

- Xử lý và Phân tích Dữ liệu Lớn: AI có thể giúp xử lý và phân tích lượng lớn dữ liệu sinh học, từ đó tạo ra thông tin quan trọng cho nghiên cứu.



GS.TS. Đỗ Phúc, 2024

148

Dùng HMM trong phân tích chuỗi

- Dự đoán gen:
 - Khám phá mẫu
 - Dự đoán cấu trúc gen
 - HMM profile
 - Xác định yếu tố lặp lại
- Mô hình hóa cây phát sinh loài:
 - Phát hiện biến thể số lần sao chép (CNV)
 - Xác định các điểm kết hợp protein
 - Mô hình hoá methylation DNA
 - Phát hiện tái tổ hợp

GS.TS. Đỗ Phúc, 2024

149

Dùng ANN trong phân tích chuỗi

- Dự đoán gen
- Dự đoán biến đổi di truyền
- Dự đoán bộ kích hoạt và tăng cường
- Dự đoán cấu trúc bậc 2
- Gọi biến thể
- Đa ngành di truyền
- Dự đoán chức năng protein
- Khám phá thuốc
- Dự đoán liên kết protein-DNA trong phát sinh loài
- Phân tích phát sinh loài
- Định liên kết yếu tố transcription
- Phát hiện biến thể số lần sao chép (CNV)

GS.TS. Đỗ Phúc, 2024

150

Dùng DL để phân tích chuỗi


- Dự đoán cấu trúc protein
- Dự đoán cấu trúc phụ
- Tính chỉnh cấu trúc thứ cấp
- Tính chỉnh cấu trúc thứ cấp
- Dự đoán tương tác protein-protein
- Dự đoán chức năng từ cấu trúc
- Dự đoán bản đồ liên hệ
- Dự đoán sự kết hợp protein-ligand
- Phân loại cấu trúc protein
- Dự đoán thuộc tính protein
- Phát hiện đồng dạng từ xa của protein

GS.TS. Đỗ Phúc, 2024

151

Graph Neural Network

GNN là viết tắt của "Graph Neural Network", là một loại mạng nơ-ron sử dụng để xử lý dữ liệu dạng đồ thị. GNN là một kiến trúc mạng nơ-ron được thiết kế để áp dụng các phép toán trên các cấu trúc dữ liệu đồ thị, như là mạng phân loại, mạng hồi quy và mạng gom cụm trên đồ thị. Điều này cho phép GNN làm việc trực tiếp với các dữ liệu đồ thị trong nhiều ứng dụng, bao gồm phân loại ảnh, dịch máy, phát hiện tội phạm mạng, và nhiều ứng dụng khác.




GS.TS. Đỗ Phúc, 2024


152

Phân tử là đồ thị (graphs)!

- Cách tự nhiên để biểu diễn phân tử là đồ thị (graph) trong đó:
 - Nguyên tử là nodes, liên kết (bonds) là cung
 - Các đặc trưng như loại nguyên tử, loại liên kết, điện tích



Phân tử là đồ thị




(Left) 3d representation of the Caffeine molecule (Center) Adjacency matrix of the bonds in the molecule (Right) Graph representation of the molecule.

GS.TS. Đỗ Phúc, 2024

154


GNNs để phân lớp phân tử

- Dự đoán phân tử là thuốc tiềm năng.
 - Thực hiện phân lớp nhị phân để biết thuốc sẽ ức chế vi khuẩn (*E.coli*)
 - Huấn luyện tập dữ các hợp chất đã biết rõ phản ứng.



Dùng Graph Neural Networks (GNN) trong Sinh Tin học

- Dự đoán tính chất và hoạt động của phân tử:** GNNs có thể học biểu diễn dữ liệu phân tử, chẳng hạn như cấu trúc hoặc tính chất hóa học của chúng, từ dữ liệu đồ thị phân tử, giúp dự đoán tính chất và hoạt động của các phân tử mới.
- Phân loại protein:** GNNs có thể được sử dụng để phân loại các protein dựa trên các đặc trưng đồ thị của chúng, giúp xác định chức năng và tương tác của protein.
- Dự đoán tương tác protein-protein:** GNNs có thể được áp dụng để dự đoán tương tác giữa các protein, giúp hiểu rõ hơn về các mạng lưới tương tác phức tạp trong tế bào và cơ thể.



GS.TS. Đỗ Phúc, 2024

156

Dùng Graph Neural Networks (GNN) trong Sinh Tin học

- Dự đoán tác dụng của thuốc:** GNNs có thể được sử dụng để dự đoán tác dụng của các phân tử hóa học hoặc thuốc trên các mạng lưới tương tác phân tử, giúp tìm ra các phân tử có tiềm năng làm thuốc.
- Phân tích dữ liệu sinh trường phân tử (omics data):** GNNs có thể được áp dụng để phân tích và khai phá dữ liệu từ các nền tảng sinh trường phân tử như dữ liệu genomic, transcriptomic, proteomic, và metabolomic, giúp hiểu rõ hơn về mối quan hệ giữa các yếu tố trong hệ thống sinh học.



GS.TS. Đỗ Phúc, 2024

157

Phân tích vi sinh học Metagenomic Analysis

- Metagenomic Analysis là một phương pháp nghiên cứu trong lĩnh vực sinh học phân tử mà không cần phải phân lập và nuôi cấy các vi sinh vật trong môi trường nghiên cứu. Thay vào đó, nó tập trung vào nghiên cứu và phân tích DNA hoặc RNA được trích xuất trực tiếp từ một mẫu môi trường phức tạp, chẳng hạn như một mẫu đất, nước, hoặc ruột người.
- Phương pháp này thường sử dụng các kỹ thuật DNA sequencing để đọc và phân tích các đoạn gene từ mẫu môi trường.
- Ứng dụng của Metagenomic Analysis rất đa dạng, từ nghiên cứu sinh thái môi trường đến phân tích vi khuẩn trong đường ruột người.

GS.TS. Đỗ Phúc, 2024

158

Gene là gì?

- Gene là một đơn vị cơ bản của di truyền, được định nghĩa là một đoạn của DNA mà chứa thông tin di truyền để sản xuất một sản phẩm sinh học nhất định, chủ yếu là protein. Mỗi gene chứa một chuỗi các nucleotides, và thông tin trong gene được chuyển hóa thành mRNA sau đó dịch ra từng phân tử protein.
- Vùng điều chỉnh (Regulatory regions): Bao gồm các khu vực như promotor và enhancer, điều chỉnh việc hoạt động của gene.
- Vùng mã hóa (Coding region): Là phần của gene chứa các exon, là các đoạn DNA được chuyển hóa thành mRNA và sau đó dịch ra từng phân tử protein.
- Vùng không mã hóa (Non-coding region): Bao gồm các intron, các vùng không mã hóa được loại bỏ trong quá trình biến dịch từ mRNA thành protein.
- Gene đóng vai trò quan trọng trong quá trình di truyền của sinh vật, quy định các đặc điểm di truyền như màu da, màu mắt, và nhiều tính chất sinh học khác. Chúng cũng đóng vai trò quan trọng trong việc điều chỉnh các quá trình sinh học trong cơ thể như sự phát triển, chức năng tế bào, và phản ứng của cơ thể đối với môi trường.

GS.TS. Đỗ Phúc, 2024

159

Tìm Gene trong chuỗi DNA bằng Học máy

- Tìm gene bằng cách sử dụng máy học liên quan đến việc phát triển các thuật toán có thể tự động xác định và chú thích vị trí của các gene trong các chuỗi DNA.
- Đây là nhiệm vụ quan trọng trong sinh học thông tin và gen học, vì nó giúp các nhà nghiên cứu hiểu về cấu trúc gen của các sinh vật và có thể dẫn đến các hiểu biết về các quy trình sinh học khác nhau.
- Dưới đây là một phác thảo tổng quan về cách máy học có thể được áp dụng vào việc tìm gene:
- 1. Thu thập Dữ liệu:** Bước đầu tiên là thu thập một tập dữ liệu lớn các chuỗi DNA cùng với các chú thích gen tương ứng. Các chú thích này chỉ ra các điểm bắt đầu và kết thúc của các gene trong các chuỗi.
- 2. Trích xuất Đặc trưng:** Cần trích xuất các đặc trưng từ các chuỗi DNA có thể được đưa vào mô hình máy học. Các đặc trưng này có thể bao gồm các mô típ chuỗi khác nhau, thành phần nucleotit, hoặc các đặc trưng phức tạp hơn được tạo ra từ dữ liệu chuỗi.

GS.TS. Đỗ Phúc, 2024

160

Tìm Gene trong chuỗi DNA bằng Học máy

- 3. Gán nhãn Dữ liệu:** Dữ liệu cần được gán nhãn, chỉ ra các phần của chuỗi DNA tương ứng với các gene và các phần không phải là gene. Dữ liệu đã được gán nhãn này sẽ được sử dụng để huấn luyện mô hình máy học.
- 4. Lựa chọn Mô hình:** Các mô hình máy học khác nhau có thể được áp dụng vào các nhiệm vụ tìm gene, bao gồm Mô hình Markov Ẩn (HMMs), Máy vector hỗ trợ (SVMs), Rừng ngẫu nhiên, Mạng nơ-ron tích chập (CNNs), Mạng nơ-ron hồi tiếp (RNNs), hoặc các kiến trúc tiên tiến hơn như Transformer.
- 5. Huấn luyện Mô hình:** Mô hình được lựa chọn được huấn luyện bằng cách sử dụng tập dữ liệu đã được gán nhãn. Trong quá trình huấn luyện, mô hình học cách ánh xạ các chuỗi DNA đầu vào vào các chú thích gen tương ứng của chúng.
- 6. Đánh giá:** Mô hình đã được huấn luyện được đánh giá bằng cách sử dụng dữ liệu kiểm tra riêng biệt để đánh giá hiệu suất của nó. Các chỉ số đánh giá thông thường bao gồm độ chính xác, độ chính xác, F1 score và độ chính xác.

GS.TS. Đỗ Phúc, 2024

161


Tìm Gene trong chuỗi DNA bằng Học máy

- 7. Tinh chỉnh và Tối ưu hóa:** Mô hình có thể được tinh chỉnh và tối ưu hóa để cải thiện hiệu suất của nó hơn nữa. Điều này có thể bao gồm điều chỉnh các siêu tham số, sửa đổi kiến trúc mô hình, hoặc sử dụng các kỹ thuật như tăng dữ liệu.
- 8. Triển khai:** Sau khi mô hình đã được huấn luyện và đánh giá một cách đủ đáng, nó có thể được triển khai để dự đoán gene trong các chuỗi DNA mới, chưa được nhìn thấy trước đó.
- 9. Xử lý Sau quá trình:** Các bước xử lý sau quá trình có thể được áp dụng để tinh chỉnh các dự đoán, chẳng hạn như lọc ra các dự đoán gene ngắn hoặc không đáng tin cậy, hoặc tích hợp kiến thức sinh học bổ sung.
- 10. Cải thiện lặp đi lặp lại:** Tìm gene là một lĩnh vực nghiên cứu liên tục, và các mô hình có thể được liên tục cải thiện và hoàn thiện khi có thêm dữ liệu hoặc khi có các thuật toán tốt hơn được phát triển.

GS.TS. Đỗ Phúc, 2024

162


Tìm Gene trong chuỗi DNA bằng Học máy



GS.TS. Đỗ Phúc, 2024

163

Coding region



GS.TS. Đỗ Phúc, 2024

164

Coding region

- Vùng mã hóa (coding region) của một gene là phần của DNA mà mã hóa thông tin để tạo ra một protein. Trong một gene, vùng mã hóa bao gồm các exon, là các phần của gene được chuyển hóa thành mRNA và sau đó được dịch ra từng phần tử protein.
- Trong quá trình tìm kiếm gene bằng máy học, việc xác định vị trí của vùng mã hóa trong DNA rất quan trọng để hiểu được cấu trúc và chức năng của gen.
- Các phương pháp máy học, ANN, DL có thể được sử dụng để dự đoán vùng mã hóa bao gồm:
 - 1. Phát hiện mẫu (Pattern recognition):** Máy học có thể được sử dụng để tìm kiếm các mẫu nucleotit đặc trưng trong DNA, như các mẫu nucleotit mở đầu (start codons) và kết thúc (stop codons), cũng như các mẫu màu xanh lá cây (conserved motifs) có thể chỉ ra vùng mã hóa.

GS.TS. Đỗ Phúc, 2024

165


Coding region

- 2. Sử dụng các mô hình dựa trên đặc trưng (Feature-based models):** Các đặc trưng từ DNA sequence như compositional features (tổng hợp đặc trưng), structural features (đặc trưng cấu trúc), và evolutionary features (đặc trưng tiến hóa) có thể được sử dụng để huấn luyện mô hình dự đoán vị trí của vùng mã hóa.
 - 3. Học sâu (Deep learning):** Các kiến trúc mạng nơ-ron sâu như Convolutional Neural Networks (CNNs) và Recurrent Neural Networks (RNNs) có thể được sử dụng để học các đặc trưng phức tạp từ các chuỗi DNA và dự đoán vùng mã hóa.
 - 4. Kết hợp các phương pháp trên:** Thường thì, sự kết hợp của nhiều phương pháp máy học khác nhau có thể cải thiện độ chính xác của việc dự đoán vùng mã hóa.
- Khi xác định được vị trí của vùng mã hóa, các nhà nghiên cứu có thể tiếp tục nghiên cứu chức năng của các gen và hiểu rõ hơn về cách mà các gen này tham gia vào các quá trình sinh học khác nhau.

GS.TS. Đỗ Phúc, 2024

166

Protein Structure



GS.TS. Đỗ Phúc, 2024

167

Dự đoán cấu trúc bậc 2


- Secondary Structure Prediction** là quá trình dự đoán cấu trúc bậc 2 (secondary structure) của một chuỗi polypeptide (chẳng hạn là một chuỗi protein) từ thông tin chuỗi AA. Trong protein, cấu trúc phụ thường được chia thành ba loại chính: α -helix, β -sheet, và turns (uốn cong).
- Các thuật toán máy học, như Support Vector Machines (SVM) hoặc Neural Networks, HMM thường được sử dụng để huấn luyện mô hình dự đoán dựa trên các đặc trưng của chuỗi amino acid.
- Secondary Structure Prediction** có thể hỗ trợ trong nghiên cứu về chức năng protein và thiết kế protein trong lĩnh vực sinh học phân tử.



GS.TS. Đỗ Phúc

168

Dự đoán cấu trúc bậc 2 của Protein



Structure to Function of Protein

Klein DSSP	Susundh B Kohn	Susundh J Kohn	Nathan Kohn
α -helix	H	H	Helix
β -sheet	G	E	Sheet
Loop/turn	L	C	Coil/loop
Random coil	I		

GS.TS. Đỗ Phúc, 2024

169

DNA2vec



GS.TS. Đỗ Phúc, 2024

170


DNA2vec

- Một trong những biểu diễn phổ biến của chuỗi DNA dài là chia nó thành các thành phần k-mer ngắn hơn.
- Thật không may, việc mã hóa vector trực tiếp của k-mer dưới dạng vector one-hot dễ bị tác động bởi vấn đề của không gian chiều. Càng tối tệ hơn, khoảng cách giữa bất kỳ cặp vector one-hot nào đều là như nhau. Điều này đặt ra vấn đề đặc biệt khi áp dụng các thuật toán học máy mới nhất để giải quyết các vấn đề trong phân tích chuỗi sinh học.
- Bài báo đề xuất một phương pháp mới để huấn luyện biểu diễn phân tán của các k-mer có chiều dài biến đổi. Phương pháp của chúng tôi dựa trên mô hình những từ phổ biến word2vec, được huấn luyện trên một mạng nơ-ron hai tầng.
- Các thử nghiệm của chúng tôi cung cấp bằng chứng cho việc tổng hợp của các vector dna2vec tương đương với việc nối các nucleotide. Chúng tôi cũng chứng minh rằng có sự tương quan giữa điểm tương đồng Needleman-Wunsch và điểm tương đồng cosin của các vector dna2vec.

GS.TS. Đỗ Phúc, 2024

171

DNA2vec with k-mer



GS.TS. Đỗ Phúc, 2024

172

DNA sequences->DNA2vec

```

c Define the DNA sequences
dna_sequences = [
    'ATGATGATGATG',
    'CGATGATGATG',
    'ATGATGATGATG',
    'CGATGATGATG'
]

DNA2vec_embeddings = [
    [ 2.584646e-02 -1.368647e-02 1.293671e-02 8.556262e-04
      -1.316297e-02 1.826901e-03 -5.924872e-03 -2.217228e-02
      -3.317009e-03 1.611280e-02],
    [ 2.584646e-02 -1.368647e-02 1.293671e-02 8.556262e-04
      -1.316297e-02 1.826901e-03 -5.924872e-03 -2.217228e-02
      -3.317009e-03 1.611280e-02],
    [ 2.584646e-02 -1.368647e-02 1.293671e-02 8.556262e-04
      -1.316297e-02 1.826901e-03 -5.924872e-03 -2.217228e-02
      -3.317009e-03 1.611280e-02],
    [ 2.584646e-02 -1.368647e-02 1.293671e-02 8.556262e-04
      -1.316297e-02 1.826901e-03 -5.924872e-03 -2.217228e-02
      -3.317009e-03 1.611280e-02]
]

```

Biểu diễn DNA sequences theo dạng Embedding vector. Dạng tiện cho học máy, học sâu

GS.TS. Đỗ Phúc, 2024

173

Các bài toán sinh tin học có độ phức tạp cao

- 1. Phân loại hình ảnh y tế:**
 - Bài toán đòi hỏi mô hình máy học phải phân loại hình ảnh y tế, như hình ảnh từ máy CT hoặc MRI, để xác định các bệnh nhân có các tình trạng khác nhau như ung thư, đột quỵ, hay các vấn đề sức khỏe khác.
- 2. Dự đoán cấu trúc protein:**
 - Dự đoán cấu trúc 3D của protein từ dãy axit amin, là một bài toán sinh học máy tính phức tạp, đặc biệt quan trọng trong việc hiểu về chức năng protein và phát triển các phác đồ thuốc.
- 3. Phân tích dữ liệu genomes:**
 - Bài toán này bao gồm việc xử lý và phân tích dữ liệu genôm để tìm ra các biểu hiện gen, liên kết giữa gen và các bệnh lý, hay dự đoán các biểu hiện gen trong điều kiện khác nhau.
- 4. Mô phỏng sinh học tế bào:**
 - Mô phỏng và mô hình hóa quá trình sinh học tế bào có thể đòi hỏi tính toán lớn để mô tả các tương tác phức tạp giữa các phân tử và các cơ chế tế bào.

GS.TS. Đỗ Phúc, 2024

174


Các bài toán sinh tin học có độ phức tạp cao

- 5. Dự đoán tương tác protein - protein**
 - Bài toán dự đoán cách các protein tương tác với nhau trong một tế bào. Điều này có thể giúp hiểu rõ hơn về các mạng tương tác protein và có thể dẫn đến phát hiện mới trong nghiên cứu về các tác nhân gây bệnh.
- 6. Mô hình hóa động lực học tương tác gen:**
 - Xây dựng mô hình động lực để mô phỏng cách các gen tương tác với nhau theo thời gian và làm thế nào chúng ảnh hưởng đến sự phát triển của các hệ thống sinh học.
- 7. Dự đoán phát triển:**
 - Bài toán dự đoán cách một hệ thống sinh học phát triển theo thời gian, ví dụ như dự đoán sự phát triển của một loài cá trong một môi trường cụ thể.

GS.TS. Đỗ Phúc, 2024

175

Multiple Sequence Alignment



GS.TS. Đỗ Phúc, 2024

176

Đề tài ứng dụng Sinh Tin học

Đề tài: Xây dựng mô hình và công cụ tin học để xử lý thông tin về gen hỗ trợ nghiên cứu ứng dụng trong CNSH tại Việt Nam.
CN GS.TS. Hoàng Kiếm PGS.TS. Nguyễn Văn Uyên. 2001





- Xây dựng Web Site CNSH
- Xây dựng phần mềm xử lý trình tự SH GENESYS2000
- Thiết kế Plasmid, chuyển nạp Gen vào cây thuốc lá, nâng cao khả năng kháng bệnh

GS.TS. Đỗ Phúc, 2024

178

Hội nghị Quốc tế InCob 2002 về Bioinformatics tại Bangkok


Hoang Kiem, Do Phuc,
GENESYS2000 a Software tool for biological analysis and application to the transgenic tobacco plant
In InCob 2002: The International Conference On Bioinformatics 2002, Bangkok, Thailand



GS.TS. Đỗ Phúc, 2024

179

Bản đồ plasmid vẽ từ phần mềm GENESYS2000



GS.TS. Đỗ Phúc, 2024

180

Workshop on Computational Biology. From Structure to Function, 2004



GS.TS. Đỗ Phúc, 2024

181

Đề tài: Nghiên cứu ứng dụng Tin Sinh học trong việc thiết kế và phát triển thuốc. CN. PGS TS Bùi Văn Lê, 2010

- Thiết kế Vaccine và thuốc
- Nghiên cứu các chương trình dự đoán Epitope từ kháng nguyên virus
- Epitope tế bào T là những đoạn peptide mạnh thắng gắn với MHC (Major Histocompatibility Complex)
- Dùng HMM, ANN, SVM dự báo các peptide gắn MHC lớp I



GS.TS. Đỗ Phúc, 2024

182

Chữa bệnh bằng liệu pháp gen là việc sử dụng liệu pháp gen để điều trị ung thư.

- Một trong những phương pháp phổ biến là sử dụng vectơ virus để chuyển giao gene vào các tế bào ung thư, giúp chúng tự phá hủy hoặc kích thích hệ miễn dịch nhận biết và tấn công tế bào ung thư.
- Ví dụ cụ thể, một liệu pháp gen được sử dụng trong điều trị ung thư là CAR-T cell therapy. Trong liệu pháp này, các tế bào cơ bản của hệ thống miễn dịch được thu thập từ bệnh nhân, sau đó được "tập" với một gen được thiết kế để nhận diện và tấn công tế bào ung thư. Các tế bào CAR-T được trở lại vào cơ thể bệnh nhân, nơi chúng tiếp tục hoạt động và tấn công tế bào ung thư mà không gây tổn thương đến các tế bào khỏe mạnh. Điều này có thể dẫn đến giảm kích thước của khối u hoặc thậm chí là hủy diệt hoàn toàn nó.

GS.TS. Đỗ Phúc, 2024

183

Tính toán phân tán trên Apache Spark có thể được áp dụng cho bài toán Multiple Sequence Alignment (MSA), nhưng có một số thách thức và cần nhắc cần xem xét.

- 1. Phân chia dữ liệu:**
 - MSA thường đòi hỏi sự tương tác giữa các chuỗi, điều này có thể tạo ra thách thức trong việc phân chia dữ liệu cho các nút tính toán khác nhau. Phân chia không tốt có thể dẫn đến việc mất mát thông tin và làm giảm chất lượng của alignment.
- 2. Giao tiếp giữa các nút:**
 - Việc thực hiện MSA trên nhiều nút đòi hỏi sự truyền thông tin giữa các nút tính toán. Điều này đôi khi có thể làm tăng độ trễ do chi phí của việc truyền thông và đồng bộ dữ liệu giữa các nút.
- 3. Thách thức về bộ nhớ:**
 - Bài toán MSA đôi khi đòi hỏi lượng lớn bộ nhớ, đặc biệt là khi đối mặt với số lượng và độ dài lớn của chuỗi. Việc quản lý bộ nhớ trên nhiều nút có thể trở thành một vấn đề, và bạn cần đảm bảo rằng hệ thống của bạn có đủ tài nguyên.

GS.TS. Đỗ Phúc, 2024

184

Tính toán phân tán trên Apache Spark có thể được áp dụng cho bài toán Multiple Sequence Alignment (MSA), nhưng có một số thách thức và cần nhắc cần xem xét.


- 4. Hiệu suất:**
 - Tùy thuộc vào cách bạn phân chia công việc và tận dụng tính toán đa nút của Spark, hiệu suất có thể thay đổi. Cần kiểm soát và tối ưu hóa phương pháp tính toán để đảm bảo hiệu suất tốt nhất.
- 5. Thư viện và công cụ hỗ trợ:**
 - Cần xem xét việc sử dụng các thư viện hoặc công cụ hỗ trợ đã được xây dựng trên nền tảng Apache Spark để giảm bớt gánh nặng việc triển khai và quản lý.
- 6. Các phương pháp tiếp cận:**
 - Có thể cần thay đổi hoặc tinh chỉnh các phương pháp tiếp cận MSA để phù hợp với môi trường tính toán phân tán.
- Mặc dù có những thách thức, nhưng việc sử dụng Apache Spark có thể mang lại lợi ích về khả năng mở rộng và tăng cường hiệu suất đối với bài toán MSA, đặc biệt là khi bạn đối mặt với dữ liệu lớn và phức tạp.

GS.TS. Đỗ Phúc, 2024

185

NUS Computational Biology

NUS Computational Biology



GS.TS. Đỗ Phúc, 2024

188

PHUC DO (UIT)
WONG LIM SOON


Prof. Ian Witton (University of Waikato) , Prof. Wong Lim Soon (NUS), Prof. Phuc Do (UIT)



GS.TS. Đỗ Phúc, 2024

189

Khóa học mới: AI and Bioinformatics



GS.TS. Đỗ Phúc, 2024

190

Course Title: Artificial Intelligence in Bioinformatics

Professor in charge: Prof. Dr. Do Phuc
University of Information Technology, VNU-HCMC

Course Overview: This course explores the intersection of artificial intelligence and bioinformatics, focusing on the application of AI techniques to analyze biological data. Students will gain hands-on experience with tools and algorithms used in bioinformatics, with an emphasis on machine learning and data mining techniques.

Week 1: Introduction to Bioinformatics and Artificial Intelligence

- Overview of bioinformatics and its applications

- Introduction to artificial intelligence and its relevance in bioinformatics

- Ethical considerations in the use of AI in biological research

Week 2: Fundamentals of Biology and Genomics

- Basics of molecular biology and genetics

- DNA sequencing technologies

- Genomic data storage and retrieval

Week 3: Introduction to Machine Learning for Bioinformatics

- Basic principles of machine learning

- Supervised and unsupervised learning in bioinformatics

- Feature selection and dimensionality reduction techniques

Week 4: Application of AI in Sequence Analysis

- Sequence alignment algorithms

- Machine Learning Models (SVMs) in bioinformatics

- Feature engineering for protein structure and function

Week 5: AI in Drug Discovery and Biomarkers

- Accelerating drug discovery with AI

- Customized biomarkers for gene expression data

- Data mining for extracting biological knowledge from literature

Week 11: Deep Learning in Bioinformatics

- Introduction to neural networks

- Convolutional Neural Networks (CNNs) for image-based bioinformatics

- Recurrent Neural Networks (RNNs) for sequence analysis

Week 12: Integration of Multi-Omics Data

- Integrating data from genomics, transcriptomics, proteomics, and metabolomics

- Network-based approaches for understanding biological systems

Week 13: Project Work and Case Studies

- Hands-on project: Applying machine learning to real-world bioinformatics problems

- Case studies of successful applications of AI in bioinformatics research

Assessment

- Midterm Exam

- Assignments and Quizzes

- Final Project Presentation and Report

Prerequisites

- Basic knowledge of biology and genetics

- Familiarity with programming (preferably Python)

- Understanding of basic statistics

References

[1] Hathi Isakshah, Deep Learning in Bioinformatics, Academic Press, 2022

[2] David Hand and Michael Karmali, Intelligent Bioinformatics, John Wiley & Sons Ltd, 2005


[3] Ian H. Witten, Eibe F. Rasmussen, Machine Learning in Bioinformatics, John Wiley & Sons Ltd, 2009

Activate V
Go to Settings

GS.TS. Đỗ Phúc, 2024

191

Dùng chatGPT với BioInformatics




GS.TS. Đỗ Phúc, 2024

193

ChatGPT with BioInformatics

Giải thích khái niệm




GS.TS. Đỗ Phúc, 2024

194

ChatGPT with BioInformatics


Lập trình xử lý dữ liệu sinh học



GS.TS. Đỗ Phúc, 2024

195


PySpark for finding the motif of DNA sequences




GS.TS. Đỗ Phúc, 2024

197

Finding The approximate motifs




Profile HMM



GS.TS. Đỗ Phúc, 2024

198

Phân tích dữ liệu sinh học



GS.TS. Đỗ Phúc, 2024

199

Đề xuất chương trình nghiên cứu về AI của ĐHQg Tp.HCM

- 2.2. Phát triển nghiên cứu ứng dụng AI phục vụ con người và xã hội trên nguyên tắc "lấy con người làm trung tâm"
- Thúc đẩy nghiên cứu ứng dụng Sinh Tin Học (Bio Informatics hay Computational Biology) vào chăm sóc sức khỏe. Đặc biệt ứng dụng AI trong BioInformatics.
- Tính toán Phân tử để phân tích và khai phá dữ liệu sinh học quy mô lớn.
- Ứng dụng Sinh Tin học trong khám phá thuốc mới và thiết kế thuốc và vaccine, Khám phá dữ liệu sinh Tin học phục vụ sản xuất sức khỏe
- Xây dựng Bộ gene người Việt phục vụ khám phá và chữa bệnh của người Việt,
- Thúc đẩy nghiên cứu liên ngành Toán, Tin học, Hóa, Sinh, Vật lý....
- Mở các course về AI in Bioinformatics. Tiến hành các đề tài nghiên cứu về AI in bio Informatics phục vụ chăm sóc sức khỏe.
- GS.TS.Đỗ Phúc
- Ngày: 13-03-2024

GS.TS. Đỗ Phúc, 2024

200

Kết luận

- Với dữ liệu tràn ngập hiện nay, phương pháp tính toán trở nên rất cần thiết đối với nghiên cứu sinh học.
- Trí tuệ nhân tạo (AI) giúp giải quyết các bài toán khó của sinh học dựa trên nguồn dữ liệu sinh học khổng lồ sẵn có
- Ứng dụng AI trong sinh học như dự đoán cấu trúc bậc 2, Metagenomic Analysis, thiết kế thuốc,
- Tính toán hiệu suất cao cho Sinh Tin học
- Dùng ChatGPT với Sinh Tin học
- Môn học mới: Artificial Intelligence in Bio Informatics:

GS.TS. Đỗ Phúc, 2024

201

Human and AI: we are together for better life



GS.TS. Đỗ Phúc, 2024

202


Một số bài báo Sinh Tin Học đã xuất bản

- Đỗ Phúc, Mai Xuân Hùng, Phát triển thuật toán tạo cây phân loại, Tạp chí phát triển khoa học và Công nghệ ĐHQG TP.HCM, ISSN 1859-0218, Vol 3, pp 1-8, 2000
- Hoang Kiem, Do Phuc, Discovering the motif based association rules from set of DNA sequences, Lecture Notes in Artificial Intelligence 2005, Springer, ISSN 0302-9743, RSCTC 2000, Banff, Canada, pp 386-390, 2000
- Do Phuc, Hoang Kiem, Developing a motif based clustering algorithm for supporting the similarity query in a database of DNA sequences, Journal of Science and Technology VNU-HCM, ISSN 1859-0218, Vol 4+5, pp 83-89, 2001
- Nguyễn Thanh Tùng, Trần Linh Thuộc, Đỗ Phúc, Prediction of protein secondary structure based n SCOP folds using Hidden Markov Model (HMM) and decision tree, Journal of BioTechnology Vietnamese Academy of Science and Technology, ISSN: 1811-4989, Vol 2, Issue 4, pp 407-414, 2004
- Đỗ Phúc, Hoàng Kiem, Using MTree structure for similarity search in biological sequence databases, Sinh học, Viện Hàn Lâm Khoa học và Công nghệ Việt Nam, ISSN: 1811-4989, Vol 4, pp 151-158, 2006
- Đỗ Phúc, Nguyễn Thị Kim Phụng, Using Spectral Vectors and M-Tree for Graph Clustering and Searching in Graph Databases of Protein Structures, International Journal of Computer, Electrical, Automation, Control and Information Engineering ISSN: 2010-3778, Vol 3, no.8, 2008
- Phạm Quốc Đàm, Đỗ Phúc, Lê Thị Thanh Mai, Dự đoán phân loại của Enzyme bằng cách áp dụng kỹ thuật khai thác dữ liệu, Tạp chí Phát triển Khoa học ĐHQG TPHCM, ISSN 1859-0218, vol 11, issue 5, pp 247-252, 2008

GS.TS. Đỗ Phúc, 2024

203

Youtube Learning Materials



GS.TS. Đỗ Phúc, 2024

204

Book References



GS.TS. Đỗ Phúc, 2024

205

Book References



GS.TS. Đỗ Phúc, 2024

206

Book References



GS.TS. Đỗ Phúc, 2024

207

References

- PatrickNg.dna2vec:Consistentvectorrepresentationsof variable-lengthk-mers, arXiv:1701.06279v1 [q-bio.QM] 23 Jan 2017
- Lea Mathias, Deep Learning Approaches in Bioinformatics: Challenges and Opportunities , Department of Computer Science, University of Cambridge, 2020
- Seonwoo Min, Byunghan Lee, and Sungroh Yoon, Deep Learning in Bioinformatics, Interdisciplinary Program in Bioinformatics, Seoul National University, Seoul 151-747, Korea , 2020
- Yu Li et al., Deep learning in bioinformatics: introduction, application, and perspective in big data era, <https://doi.org/10.1101/563601>
- Edward Keedwell, Ajit Narayanna, Intelligent Bio Informatics, the application of Artificial Intelligence to Bioinformatics Problems, Wiley, 2005
- Jacques Nicolas, Artificial Intelligence and Bioinformatics, HAL Id: hal-01850570 2020
- Christof Angermueller et al., Deep learning for computational biology, European Molecular Biology Laboratory, European Bioinformatics Institute, Wellcome Trust Genome Campus, Hinxton, Cambridge, UK, 2016

GS.TS. Đỗ Phúc, 2024

208

Q&A

Thank you for your kind attention!

GS.TS. Đỗ Phúc, 2024

209